

Pemanfaatan Data AIS dalam Pemodelan Nowcasting Statistik Ekspor Impor Indonesia

Jimmy Nickelson (221709765, 4SD2)

Dosen Pembimbing: Rani Nooraeni, SST., M.Stat.

Ringkasan— AIS merupakan salah satu sumber *big data* yang berpotensi untuk dimanfaatkan sebagai sumber data baru, yaitu untuk mengembangkan indikator terkait statistik ekspor impor. Dalam penggunaannya, diperlukan tahap *preprocessing* yang tepat untuk dapat menggambarkan data ekspor impor dengan baik. Publikasi data ekspor impor Indonesia sendiri memiliki *timeliness* yang kurang, sehingga data AIS dapat menjadi alternatif solusi untuk meramalkan nilai dan volume ekspor impor secara *real-time*. Dari data AIS dapat dibentuk indikator ekspor impor dan menjadi variabel prediktor dalam model peramalan. Metode *Artificial Neural Network* (ANN) dipilih sebagai model peramalan. Model tersebut juga akan dibandingkan dengan model ARIMA. Hasil penelitian menunjukkan bahwa data AIS dapat digunakan untuk membentuk indikator terkait statistik ekspor impor dengan proses *cleaning* yang tepat. Nilai *error* yang dihasilkan setiap model menunjukkan bahwa ANN lebih unggul daripada ARIMA. Sedangkan model ARIMA dapat menghasilkan pola peramalan yang lebih baik daripada model ANN pada data nilai impor.

Kata Kunci— Ekspor impor, AIS, metode peramalan, ANN, ARIMA

I. LATAR BELAKANG

Big data merupakan sebuah temuan baru di bidang teknologi informasi yang seringkali dicirikan oleh 3V, yaitu Volume, Velocity, dan Variety. Namun dalam pemanfaatan *big data* diperlukan tahapan *preprocessing* yang baik dan benar untuk mendapatkan *insight* baru yang akurat. Salah satu contoh *big data* adalah sinyal Sistem Identifikasi Otomatis atau *Automatic Identification System* (AIS). Data AIS dipancarkan oleh kapal secara periodik dan diterima melalui stasiun pangkalan AIS yang terletak di tepi daratan atau melalui penerima satelit. Data AIS merekam kapal-kapal yang melakukan pelayaran internasional secara kontinu, sehingga data tersebut dapat digunakan untuk menggambarkan pola perdagangan lintas laut secara *real-time*.

Terdapat penelitian yang menggunakan data AIS dengan tujuan untuk memprediksi ekspor minyak mentah [1]. Penelitian lainnya juga menggunakan data AIS untuk mengembangkan indikator perdagangan dan aktivitas maritim di Malta [2] ataupun indikator perdagangan lintas laut dunia menggunakan data mentah dari data AIS [3]. Tim AIS pada UN Global Platform juga menganalisis data AIS untuk digunakan dalam berbagai bidang penelitian, seperti bidang migrasi, bidang lingkungan, bidang maritim dan perikanan, juga bidang ekonomi dan perdagangan [4]. Dari penelitian-penelitian tersebut, dapat digarisbawahi bahwa AIS memiliki potensi besar dan dapat dimanfaatkan sebagai sumber data baru, seperti untuk mengembangkan indikator baru terkait perdagangan luar negeri, yang meliputi aktivitas ekspor dan impor.

Dalam penggunaan data AIS, terdapat tahap yang penting untuk bisa menghasilkan indikator terkait perdagangan, yaitu tahap *preprocessing data*. Hal ini disebabkan karena tidak semua data AIS yang dikirimkan kapal merupakan data yang terkait aktivitas perdagangan luar negeri, sehingga diperlukan pemilihan fitur yang dapat mewakili aktivitas tersebut. Dengan melakukan hal itu juga dapat mengurangi ukuran dan kompleksitas data, serta dapat mengurangi *noise* atau *outlier* pada data. Penelitian ini akan menjelaskan tahap *preprocessing* yang tepat untuk menghasilkan indikator perdagangan luar negeri menggunakan data AIS.

Di Indonesia, pengumpulan data perdagangan barang luar negeri dilakukan oleh Badan Pusat Statistik yang diperoleh dari hasil kompilasi dan survei. Data utama dikumpulkan berdasarkan dokumen-dokumen keterangan ekspor impor yang dihasilkan oleh Direktorat Jenderal Bea dan Cukai setiap bulan. Data ekspor juga berasal dari PT Pos Indonesia, catatan lain di perbatasan, dan hasil survei perdagangan lintas batas laut [5]. Namun, pada proses publikasi statistik resmi tersebut terdapat jeda waktu sejak data dikumpulkan hingga data dipublikasikan, sehingga terjadi keterlambatan dalam publikasi statistik resmi. Hal ini tentunya dapat mempengaruhi proses pengambilan kebijakan, karena pengambilan kebijakan membutuhkan data sebagai landasan penentuan kebijakan, dimana data tersebut harus sesuai dengan kondisi terkini. Untuk membantu mengurangi masalah tersebut, diperlukan peramalan atau *nowcasting* untuk menggambarkan situasi terkini dan untuk menjembatani keterlambatan publikasi statistik resmi tersebut.

Sebagai alternatif solusinya, AIS dapat menjadi indikator baru dan menjadi variabel *proxy* untuk meramalkan statistik ekspor impor. Data AIS dipancarkan oleh kapal setiap menit, sehingga dapat tersedia secara *real-time*. Hal tersebut menjadikan data AIS berpotensi untuk digunakan dalam *nowcasting*. Selain itu, mayoritas komoditas ekspor impor Indonesia menggunakan transportasi laut [5], sehingga data AIS menjadi relevan untuk digunakan dalam peramalan statistik ekspor impor di Indonesia.

Peramalan data *time series* pada umumnya dapat menggunakan metode statistik tradisional atau metode *artificial intelligence*. Model ARIMA merupakan salah satu metode statistik tradisional yang populer dan menghasilkan prediksi yang baik jika digunakan untuk data berpola linear [6]. Sedangkan metode *artificial intelligence*, seperti *Artificial Neural Network* (ANN), dapat mengenali pola dari data masa lalu, meskipun terdapat pola nonlinear atau *noise* pada data [7]. Selain itu, metode ini juga lebih fleksibel digunakan daripada metode tradisional [8].

Berdasarkan uraian tersebut, penelitian ini akan mengeksplorasi penggunaan data AIS dengan melakukan tahap

preprocessing untuk memonitor statistik ekspor dan impor. Setelah itu, indikator terkait statistik ekspor impor akan dibangun berdasarkan data tersebut. Adapun metode peramalan yang akan digunakan adalah metode ANN dan ARIMA, yang nantinya akan dipilih model terbaik untuk menghasilkan nilai indikator statistik ekspor impor. Sehingga rumusan masalah pada penelitian ini yaitu,

1. Bagaimana tahap *preprocessing* data AIS yang tepat untuk menghasilkan data atau fitur yang sesuai dengan aktivitas ekspor impor?
2. Bagaimana membentuk indikator statistik ekspor impor dari data AIS?
3. Bagaimana hasil peramalan statistik ekspor impor Indonesia menggunakan data AIS dengan metode ANN dan ARIMA?

II. TUJUAN PENELITIAN

Berdasarkan latar belakang tersebut, maka penelitian ini bertujuan untuk:

1. Melakukan *preprocessing* data AIS untuk menghasilkan data atau fitur yang sesuai dengan aktivitas ekspor impor.
2. Membentuk indikator yang dapat digunakan untuk memprediksi statistik ekspor impor dari data AIS.
3. Menerapkan metode peramalan ANN dan ARIMA untuk memprediksi statistik ekspor impor dengan data AIS.

III. KAJIAN PUSTAKA

A. Automatic Identification System (AIS)

AIS merupakan sistem komunikasi maritim internasional yang dipancarkan setiap kapal dan digunakan untuk melacak pergerakan kapal. AIS dikembangkan oleh IMO (International Maritime Organization) dengan tujuan untuk membantu kapal menghindari tabrakan dan membantu otoritas pelabuhan mengontrol lalu lintas laut secara efisien. IMO mewajibkan AIS dipasang di atas kapal pelayaran internasional dengan berat 300 *gross tonnage* (GT) atau lebih, dan semua kapal penumpang [9]. Pesan AIS secara otomatis dikirim melalui gelombang radio berfrekuensi sangat tinggi / *Very High Frequency* (VHF) dilengkapi dengan sistem GPS (*Global Positioning System*) setiap dua sampai sepuluh detik jika kapal bergerak atau setiap enam menit jika kapal diam [2].

B. Korelasi Pearson

Korelasi merupakan sebuah nilai yang menunjukkan kuat tidaknya hubungan antara dua variabel atau lebih. Koefisien korelasi pada variabel X dan Y pada n data dapat dihitung dengan menggunakan rumus seperti persamaan (1).

$$r_{XY} = \frac{n \sum_{i=1}^n X_i Y_i - \sum_{i=1}^n X_i \sum_{i=1}^n Y_i}{\sqrt{n \sum_{i=1}^n X_i^2 - (\sum_{i=1}^n X_i)^2} \sqrt{n \sum_{i=1}^n Y_i^2 - (\sum_{i=1}^n Y_i)^2}} \quad (1)$$

dimana n adalah banyaknya data, X adalah variabel independen atau variabel pertama, dan Y adalah variabel dependen atau variabel kedua. Nilai korelasi akan memiliki rentang nilai antara -1 sampai +1. Tanda negatif (-) menunjukkan hubungan antarvariabel berbanding terbalik, sedangkan tanda positif (+) menunjukkan arah sebaliknya. Semakin dekat nilai korelasi dengan angka satu menunjukkan semakin kuat hubungan antarvariabel tersebut.

C. Metode Seleksi Variabel

Seleksi variabel merupakan salah satu tahap yang penting dalam membangun model prediksi. Fokus ini yaitu menyeleksi beberapa variabel input yang dapat mendeskripsikan keseluruhan data input secara efisien dan tetap memberikan hasil prediksi data *output* yang baik, sehingga dapat membangun model yang sederhana dan lebih komprehensif [10]. Pada penelitian ini, metode seleksi variabel yang digunakan yaitu menggunakan *permutation importance*, *stepwise regression*, nilai *p-value*, dan nilai korelasi.

Permutation importance mengukur tingkat 'kepentingan' suatu variabel dengan mengacak nilai variabel tersebut. Apabila *error* suatu model bertambah setelah variabel tersebut diacak, maka variabel tersebut tergolong 'penting' dalam model, karena model memerlukan variabel tersebut untuk melakukan prediksi [11]. Selanjutnya, variabel tersebut dipilih sebagai variabel prediktor dalam model peramalan. Terdapat juga pertimbangan untuk mengeluarkan variabel apabila pengacakan tersebut justru menghasilkan *error* yang lebih kecil.

Stepwise regression memilih variabel dengan mempertimbangkan peningkatan suatu kriteria setiap variabel. Metode ini diawali dengan model tanpa variabel. Kemudian untuk setiap perulangan, variabel yang memberikan peningkatan kriteria terbesar pada model akan dimasukkan ke model. Namun terdapat juga pertimbangan untuk mengeluarkan variabel jika tidak memberikan peningkatan pada model [10].

Metode seleksi variabel juga dilakukan berdasarkan variabel yang signifikan pada suatu model, terutama model statistik tradisional. Variabel yang memiliki *p-value* kurang dari tingkat signifikansi ($\alpha=0.05$) pada model akan dipilih dan dimasukkan ke dalam model. Seleksi variabel juga dilakukan berdasarkan nilai korelasi antara variabel prediktor dengan variabel respons. Variabel yang memiliki korelasi tinggi akan memiliki hubungan linear dan memiliki efek yang hampir sama dengan variabel respons. Variabel yang berkorelasi melebihi suatu batas nilai akan dipilih sebagai variabel prediktor.

D. Metode Peramalan

AutoRegressive Integrated Moving Average (ARIMA)


Model ARIMA merupakan salah satu model peramalan data runtun waktu. Model ini merupakan kombinasi dari penurunan (*differencing*) dengan autoregresi dan model rata-rata bergerak, sehingga model ini menggunakan informasi dari observasi masa lalu untuk membuat prediksi. Persamaan model ini dapat dituliskan seperti persamaan (2).

$$y'_t = c + \phi_1 y'_{t-1} + \dots + \phi_p y'_{t-p} + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (2)$$

dimana y'_t adalah data y_t yang diturunkan (*differenced series*). Sedangkan variabel di sebelah kanan meliputi nilai lag dari y_t dan nilai lag *error*. Model ini disebut model ARIMA (p,d,q) dimana p adalah orde nilai *autoregressive*, d adalah derajat turunan yang digunakan, dan q adalah orde rata-rata bergerak (*moving average*). Model ARIMA dapat memasukkan informasi lain yang relevan untuk meningkatkan akurasi prediksi, yaitu dengan menambahkan variabel eksogen pada model, sehingga disebut model ARIMAX [12].

Artificial Neural Network (ANN)

ANN merupakan sebuah algoritma pemodelan *machine learning* yang digunakan untuk mengolah informasi dan menganalisis data. ANN dibangun mengikuti analogi sistem syaraf, yaitu dari sekumpulan unit atau neuron yang saling terhubung. Neuron-neuron tersebut terdiri dari beberapa lapisan, yaitu *input layer* sebagai lapisan untuk data input, *hidden layer* sebagai lapisan untuk memproses data, dan *output layer* sebagai lapisan untuk mengeluarkan hasil prediksi/estimasi, seperti yang terlihat pada Gambar 1. Jika arsitektur ANN memiliki lebih dari satu *hidden layer*, maka arsitektur tersebut disebut *multilayer feed-forward neural network*.



Gambar 1. Arsitektur ANN

Salah satu algoritma pembelajaran ANN adalah algoritma *backpropagation*. Algoritma ini mempelajari data dengan memproses data latih secara berulang. Untuk setiap perulangan, bobot akan disesuaikan untuk mendapatkan *error* sekecil mungkin antara hasil prediksi dengan data target sebenarnya, yang dapat berupa data label kelas atau data numerik. Modifikasi bobot ini dilakukan dengan arah ke belakang (*backward*) [13].

Metode ANN memerlukan parameter dalam membentuk modelnya. Adapun beberapa parameter tersebut seperti:

1. Jumlah *hidden layer* dan neuronnya.
2. Fungsi aktivasi, yaitu fungsi yang mengubah input yang sudah ditambah bobot dan bias menjadi nilai *output*. Fungsi ini digunakan untuk mengontrol keluaran dari neuron, sehingga hasil yang keluar bisa dibandingkan dengan batasan yang ditentukan. Beberapa contoh fungsi aktivasi seperti terlihat pada TABEL I.

TABEL I
FUNGSI AKTIVASI ANN

Nama Fungsi	Fungsi aktivasi $f(x)$
Linear	cx
Sigmoid	$\frac{1}{1+e^{-x}}$
Tanh	$\tanh(x)$
ReLU	$\max(0, x)$
Leaky ReLU	$\max(\alpha x, x)$

3. *Learning rate*, parameter yang mengontrol seberapa banyak perubahan jumlah bobot yang diperbarui selama pelatihan. Parameter ini juga mengontrol kecepatan pembelajaran model.
4. Momentum, parameter yang dapat memperlancar pembelajaran algoritma sehingga juga dapat mempercepat proses pelatihan.

Tuning Parameter ANN

Proses penentuan nilai parameter ANN merupakan hal yang penting, karena nilai tersebut dapat mempengaruhi hasil prediksi dan performa model. Maka, diperlukan *tuning parameter* untuk menentukan nilai parameter ANN yang sesuai. Salah satu metode *tuning parameter* adalah metode pencarian *random search*. *Random search* merupakan salah satu algoritma pencarian yang melibatkan pembangkitan dan evaluasi nilai acak ke suatu fungsi objektif, dalam hal ini model fungsi ANN. Nilai parameter model yang digunakan akan dibandingkan dengan bilangan acak dan dihitung nilai *error*-nya. Proses tersebut diulang dengan jumlah perulangan tertentu dan menyimpan model yang memiliki nilai *error* terkecil pada setiap perulangan. Pada akhir perulangan akan terdapat satu model yang memiliki nilai *error* terkecil dan memberikan hasil parameter yang terbaik [14].

E. Metode Evaluasi Peramalan

Untuk mengetahui keakuratan hasil peramalan dari model, maka perlu dilakukan evaluasi terhadap hasil tersebut. Metode evaluasi peramalan juga dapat digunakan untuk membantu mencari sebuah metode yang optimal dan membandingkan ketepatan dua atau lebih metode algoritma pemodelan yang berbeda. Terdapat beberapa teknik untuk mengevaluasi hasil peramalan, salah satunya menggunakan nilai RMSE (*Root Mean Squared Error*).

Metode RMSE menghitung akar kuadrat dari rata-rata selisih kuadrat antara nilai prediksi dan nilai aktual. Suatu model dikatakan memiliki performa yang bagus apabila RMSE yang dihasilkan minimum. Fungsi RMSE dapat dituliskan seperti persamaan (3).

$$RMSE = \sqrt{\sum_{t=1}^n \left(\frac{\hat{y}_t - y_t}{n} \right)^2} \quad (3)$$

dimana n adalah banyaknya data, \hat{y}_t adalah nilai prediksi, dan y_t adalah nilai sebenarnya.

IV. METODE PENELITIAN

A. Metode Pengumpulan Data

Pada penelitian ini, data yang akan digunakan adalah data AIS dan data perdagangan luar negeri Indonesia, yang meliputi nilai dan volume ekspor impor. Data AIS yang digunakan bersumber dari penyedia data AIS exactEarth via Platform Global UN. Cakupan data yang digunakan yaitu data AIS yang dikirim kapal di wilayah *bounding box* Indonesia, terutama di dalam wilayah pelabuhan-pelabuhan tertentu yang terdaftar di situs web *Maritime Safety Information (MSI)*¹, yaitu sebanyak 123 pelabuhan. Rentang data yang digunakan yaitu antara Desember 2018 hingga Desember 2020, dengan jumlah fitur sebanyak 35 dan jumlah *record* sebanyak 661.8 juta. Adapun fitur yang terdapat pada data AIS di antaranya seperti terlihat pada TABEL II.

Data statistik perdagangan luar negeri Indonesia yang digunakan adalah data ekspor dan impor yang bersumber dari

¹ National Geospatial – Maritime Safety Office, “World Port Index: Query Results of Indonesian Port”, <https://msi.nga.mil/queryResults?publications/>

world-port-index?countryName= Indonesia&output=html (diakses 8 Februari 2021).

situs web BPS². Data tersebut terdiri dari nilai dan volume ekspor impor Indonesia dalam satuan dolar US dan kilogram. Data yang digunakan merupakan data bulanan dengan rentang waktu yang sama, yaitu antara Desember 2018 hingga Desember 2020.

TABEL II
FITUR PADA DATA AIS

Nama Fitur	Keterangan
MMSI	Nomor unik kapal <i>Maritime Mobile Service Identity</i> (MMSI)
DTG	Tanggal observasi (yyyy-MM-dd'T'HH:mm:ssZ)
Vessel_type	Tipe kapal, seperti 'cargo', 'tanker', 'tug', 'passenger', dll
Nav_status	Status navigasi kapal, seperti 'at anchor', 'moored', 'aground', dll
SOG	<i>Speed Over Ground</i> , kecepatan kapal terhadap tanah atau benda tetap lainnya (knot)
COG	<i>Course Over Ground</i> , arah sebenarnya dari kemajuan kapal terhadap permukaan bumi (derajat)
Draught	Jarak vertikal antara garis air dan dasar lambung kapal (meter)
Longitude	Koordinat garis bujur dalam WGS 84 (derajat desimal)
Latitude	Koordinat garis lintang dalam WGS 84 (derajat desimal)

B. Metode Pengolahan Data

Metode Preprocessing Data

Pada data AIS bisa dimungkinkan terdapat pesan yang memiliki *noise* atau *outlier*. Misalnya, terdapat pesan yang memiliki MMSI tidak sesuai dengan ketentuan. Terdapat juga pesan yang tidak terkait dengan aktivitas ekspor impor, seperti pesan yang dikirim oleh kapal penumpang, kapal militer, dll. Untuk itu, diperlukan tahap *preprocessing* yang tepat untuk mengurangi *noise* pada data AIS dan mendapatkan data yang terkait ekspor impor, juga sekaligus menghapus fitur yang terdapat *missing data*. Tahap *preprocessing* tersebut dilakukan dengan melakukan beberapa langkah/kaidah untuk memfilter data AIS.

- **Filter 1: MMSI kapal yang valid**
MMSI kapal yang valid mempunyai jumlah karakter angka sebanyak sembilan digit [15], sehingga pesan AIS yang memiliki MMSI kurang dari atau lebih dari sembilan digit, dengan kata lain MMSI < 100000000 atau MMSI > 999999999 akan dieliminasi dari data.
- **Filter 2: kapal yang melakukan pelayaran**
Kapal yang melaporkan posisi dalam area kecil selama periode dua tahun dieliminasi dari data. Filter ini digunakan untuk menghapus kapal-kapal yang tidak meninggalkan pelabuhan atau hanya berlayar dalam area kecil selama periode tersebut tidak melakukan aktivitas perdagangan, sehingga dikeluarkan dari unit yang berkontribusi terhadap ekspor impor [16]. Ukuran area yang digunakan adalah 0.1 derajat desimal (11.1 km).
- **Filter 3: status kapal berlabuh**

Status navigasi pada data AIS menunjukkan status kapal saat pesan tersebut dikirim. Beberapa status navigasi yang ada seperti 'under way using engine', 'at anchor', 'moored', 'sailing', 'engaged in fishing', 'not under command', 'restricted manoeuvrability', 'aground', dan 'not defined'. Filter dilakukan pada pesan AIS yang status navigasi kapal yang dilaporkan terkait dengan aktivitas ekspor impor. Status navigasi yang dimaksud yaitu 'at anchor', 'moored', dan 'restricted manoeuvrability'. Kapal dengan status navigasi tersebut dapat melakukan bongkar muat atau perpindahan muatan dari/ke kapal sehingga terkait dengan aktivitas ekspor impor [17].

- **Filter 4: non-zero draught**
Draught (sarat air kapal) merupakan jarak permukaan air dengan bagian bawah kapal. Sarat air kapal dapat digunakan untuk mengestimasi potensi berat kapal yang diangkut [2]. Sarat air kapal pada pesan AIS bernilai 0.1 hingga 25.5 meter. Nilai 25.5 menunjukkan nilai sarat air 25.5 m ke atas. Sedangkan nilai nol merupakan nilai *default* atau jika tidak tersedia [15], sehingga pesan yang bernilai *draught* nol akan dieliminasi dari data.
- **Filter 5: tipe kapal yang relevan**
Tipe kapal yang ada pada data AIS seperti 'fishing', 'passenger', 'sailing', 'military', 'pilot', 'cargo', 'tanker', dll. Data AIS difilter berdasarkan tipe kapalnya yang terkait dengan aktivitas ekspor impor, yaitu kapal 'cargo' dan kapal 'tanker'. Tipe kapal ini dapat mengindikasikan komoditas kapal yang diangkut [2].
- **Filter 6: kapal yang berada di pelabuhan**
Dari data AIS yang dikirim suatu kapal akan diidentifikasi apakah kapal tersebut berada di suatu pelabuhan atau tidak. Filter ini digunakan untuk mendapatkan data kapal yang melakukan aktivitas ekspor impor di pelabuhan. Kapal ada di suatu pelabuhan dan dimasukkan sebagai data valid apabila pesan AIS dikirim di dalam *bounding box* pelabuhan tersebut. Terdapat pula pertimbangan untuk mengeliminasi data apabila kapal tersebut tidak berada di pelabuhan mana pun.

Membentuk Indikator dari Data AIS

Indikator terkait aktivitas ekspor impor akan dikembangkan dan diagregasi dari data AIS. Beberapa fitur pada data AIS dapat terlihat pada TABEL II. Dari beberapa fitur tersebut, tidak semua fitur dapat digunakan untuk membentuk indikator ekspor impor, sehingga akan dipilih fitur yang berkaitan dan dapat mewakilinya indikator ekspor impor. Fitur data AIS yang terpilih yaitu, 'MMSI', 'DTG', 'draught', 'longitude', dan 'latitude'. Adapun metode penghitungan setiap indikator dapat dijelaskan seperti TABEL III. Indikator tersebut akan menjadi variabel prediktor untuk meramalkan statistik ekspor impor.

² Badan Pusat Statistik, "Ekspor dan Impor", <https://www.bps.go.id/exim/> (diakses 8 Februari 2021)

TABEL III
INDIKATOR AIS YANG DIBENTUK

No	Nama Indikator	Keterangan
1	Waktu kapal di pelabuhan / <i>timeInPort</i> (X1)	Indikator ini menghitung rata-rata waktu yang dihabiskan kapal di suatu pelabuhan dalam satuan detik. Metode yang digunakan yaitu menghitung selisih waktu pesan AIS yang dikirimkan kapal saat berada di dalam wilayah pelabuhan. Kemudian selisih waktu tersebut dijumlahkan setiap kapal per pelabuhan. Apabila waktu yang dikirim kapal melebihi tiga hari, maka pesan tersebut akan dieliminasi dari data karena diasumsikan pesan tersebut dikirim oleh kapal yang sedang diperbaiki atau hal lain. Fitur yang digunakan: MMSI, DTG, Longitude, Latitude
2	Jumlah unik kapal di pelabuhan / <i>numVessel</i> (X2)	Indikator ini menghitung jumlah unik kapal yang masuk atau berada di wilayah pelabuhan berdasarkan nomor MMSI-nya (nomor identitas kapal), sehingga indikator ini dihitung dengan satuan jumlah kapal. Fitur yang digunakan: MMSI, DTG, Longitude, Latitude
3	Jumlah kunjungan kapal / <i>numVisit</i> (X3)	Jumlah kunjungan kapal dapat dihitung dengan menggunakan koordinat pesan AIS yang dikirimkan kapal. Apabila pesan sebelumnya dikirim di luar wilayah pelabuhan dan pesan selanjutnya dikirim di dalamnya, maka pesan tersebut dihitung satu kunjungan pada pelabuhan tersebut. Fitur yang digunakan: MMSI, DTG, Longitude, Latitude
4	Jumlah perubahan sarat air kapal / <i>numDraught Diff</i> positif (X4) dan negatif (X5)	Indikator ini menghitung jumlah kapal yang mengalami perubahan sarat air kapal saat di pelabuhan. Nilai sarat air yang semakin besar menunjukkan bahwa semakin dalam dan semakin berat kapal tersebut. Perubahan sarat kapal dihitung dengan menyelisihkan sarat air kapal pada pesan AIS selanjutnya dengan sarat air kapal yang dikirimkan pada pesan sebelumnya. Perubahan tersebut akan dibedakan menjadi kapal yang mengalami kenaikan dan kapal yang mengalami penurunan sarat air kapal. Kapal yang mengalami kenaikan sarat air kapal dapat ditunjukkan dari selisih bernilai positif dan mengindikasikan penambahan beban/berat pada kapal, indikator ini akan digunakan untuk melihat nilai/volume ekspor. Begitu pula sebaliknya. Fitur yang digunakan: MMSI, DTG, Draught, Longitude, Latitude
5	Besaran perubahan sarat air kapal / <i>sumDraught Diff</i> positif (X6) dan negatif (X7)	Indikator ini menghitung besaran perubahan sarat air kapal saat di pelabuhan dalam satuan meter. Metode penghitungan perubahan sarat air kapal sama seperti metode sebelumnya. Bedanya, indikator ini menghitung jumlah besaran perubahan yang terjadi pada setiap kapal di pelabuhan. Fitur yang digunakan: MMSI, DTG, Draught, Longitude, Latitude

Transformasi Data

Data ekspor impor dan indikator dari data AIS akan dihitung pertumbuhannya (*growth rate*) setiap bulan dengan rumus pertumbuhan seperti persamaan (4).

$$\Delta y_t = \frac{y_t - y_{t-1}}{y_{t-1}} \times 100 \quad (4)$$

dimana Δy_t adalah pertumbuhan y_t terhadap y_{t-1} ; y_{t-1} adalah data pada periode sebelumnya; dan y_t adalah data periode sekarang. Data pertumbuhan digunakan dalam penelitian ini karena

memberikan nilai korelasi yang lebih baik antara indikator AIS dengan data ekspor impor. Selain itu, transformasi ini juga digunakan untuk melihat dan membandingkan pola pergerakan kedua data, serta menjadikan data lebih stasioner. Selanjutnya, data tersebut distandardisasi menggunakan persamaan (5).

$$Z_i = \frac{x_i - \bar{X}}{S_X} \quad (5)$$

dimana \bar{X} dan S_X adalah rata-rata dan standar deviasi dari atribut X . Standardisasi berguna untuk memberikan bobot yang sama pada semua atribut, menormalkan nilai input, dan mempercepat proses pembelajaran model, terutama pada algoritma *Neural Network* [13].

Penyeleksian Variabel Prediktor

Beberapa simulasi variabel prediktor dilakukan untuk menentukan variabel input model peramalan dan mendapatkan hasil yang optimal. Adapun beberapa simulasi variabel tersebut yaitu,

1. Seluruh indikator AIS yang telah dihasilkan.
2. Indikator AIS yang diseleksi berdasarkan *permutation importance* dari model ANN.
3. Indikator AIS yang diseleksi menggunakan *stepwise regression*. Pada penelitian ini, BIC digunakan sebagai kriteria untuk menyeleksi variabel dalam model.
4. Indikator AIS yang signifikan dalam model ARIMA.
5. Indikator AIS yang memiliki korelasi dengan data ekspor impor lebih dari batas yang ditentukan, yaitu 0.25.

C. Metode Analisis

Pembagian Data Train dan Data Test

Data yang digunakan, yaitu indikator AIS dan data ekspor impor, merupakan data bulanan selama periode dua tahun. Data tersebut berjumlah 24 *series* dan akan dibagi menjadi 80% sebagai data latih dan 20% sebagai data uji. Data latih (*training set*) akan menggunakan data periode Januari 2019 hingga Juli 2020, yaitu sebanyak 19 data. Sedangkan data uji (*test set*) akan menggunakan data periode Agustus hingga Desember 2020, atau sebanyak 5 data.

Model Peramalan

Pada penelitian ini, statistik ekspor impor akan diramalkan dengan indikator dari data AIS menggunakan metode ANN dan ARIMA. Model ARIMA akan menggunakan indikator dari data AIS sebagai variabel eksogen untuk meramalkan data ekspor impor. Parameter dalam model ARIMA, yaitu d , akan menggunakan nilai 0, karena tidak melakukan *differencing* pada *series* data. Sedangkan untuk parameter p dan q akan ditentukan menggunakan nilai AIC dan BIC terkecil yang dihasilkan setiap model [6].

TABEL IV
NILAI PARAMETER ANN

Nama Parameter	Batasan Nilai Parameter
Jumlah <i>hidden layer</i>	[1, 4]
Jumlah neuron	[1, 100]
Fungsi aktivasi	{‘identity’, ‘tanh’, ‘sigmoid’, ‘relu’, ‘leaky_relu’}
<i>Learning rate</i>	[0.0, 1.0]
Momentum	[0.0, 1.0]

Untuk model ANN, arsitektur yang digunakan dalam penelitian ini yaitu *Multilayer Feed-forward Neural Network*, yang memiliki lebih dari satu *hidden layer*. Algoritma pembelajaran yang digunakan yaitu algoritma *backpropagation*, dimana bobot setiap lapisan akan disesuaikan untuk mendapatkan *error* sekecil mungkin antara hasil prediksi dengan data *target* sebenarnya. Untuk mendapatkan hasil prediksi dengan model ANN, terdapat beberapa parameter yang perlu ditentukan, seperti terlihat pada TABEL IV. Karena nilai parameter akan mempengaruhi hasil dan performa model, maka penentuan parameter dan topologi jaringan model ANN akan dilakukan dengan *tuning parameter* menggunakan *random search*. Nilai acak akan dibangkitkan pada setiap parameter ANN dengan rentang nilai batasan sesuai pada TABEL IV. Proses tersebut akan diulang dengan jumlah iterasi sebanyak 100.

V. HASIL DAN PEMBAHASAN

A. Hasil Preprocessing Data AIS

Jumlah data AIS yang digunakan, yaitu pada periode Desember 2018 hingga Desember 2020, berjumlah 661.8 juta *record*. Beberapa langkah filter dilakukan terhadap data tersebut untuk mengurangi *noise* dan mendapatkan data yang terkait ekspor impor, seperti yang sudah dijelaskan pada bab IV. TABEL V menunjukkan jumlah pesan AIS pada setiap tahap filter, mulai dari sebelum difilter hingga jumlah data setelah difilter.


TABEL V.
JUMLAH DATA AIS PADA SETIAP TAHAP FILTER

Keterangan	Jumlah Pesan AIS
Seluruh pesan AIS	661,847,517
Filter 1: MMSI kapal yang valid	655,794,385
Filter 2: kapal yang melakukan pelayaran	640,138,932
Filter 3: status kapal berlabuh	154,253,335
Filter 4: <i>non-zero draught</i>	145,645,162
Filter 5: tipe kapal yang relevan	98,837,324
Filter 6: kapal yang berada di pelabuhan	73,576,052


Pada TABEL V, dapat terlihat bahwa tahap filter ketiga, yaitu filter berdasarkan status kapal berlabuh, mengurangi banyak data atau sebesar 75% dari data sebelumnya. Filter ketiga menggunakan status navigasi kapal untuk menentukan status kapal berlabuh. Jika dilihat berdasarkan status navigasinya, maka distribusi data AIS berdasarkan data pada filter sebelumnya ditunjukkan pada Gambar 2. Status ‘under way using engine’ mendominasi data sebesar 53.57%, sedangkan status navigasi kapal yang terkait dengan aktivitas ekspor impor, yaitu ‘restricted manoeuvrability’, ‘moored’, dan ‘at anchor’ tercakup dalam data sebesar 25.09% dari data. Hal tersebut menjadikan banyak data yang dieliminasi. Terdapat pula status ‘unknown’ dan ‘not defined’ yang mencakup sekitar 12.08% dari data.

Tahap filter kelima menggunakan tipe kapal untuk menentukan tipe kapal yang terkait dengan ekspor impor. Gambar 3 menunjukkan distribusi data AIS pada tahap filter keempat jika dilihat berdasarkan tipe kapal. Terlihat bahwa tipe kapal yang terkait dengan aktivitas ekspor impor, yaitu kapal kargo dan kapal tangki, mencakup 67.9% dari data. Sisanya merupakan kapal tunda (*tug*), kapal penunjang, kapal

pengeruk, dan tipe kapal lainnya. Terdapat juga pesan yang tidak teridentifikasi atau digolongkan tipe kapal ‘unknown’ yang mencakup 3.35% dari data. Dari semua enam tahap filter tersebut, didapatkan jumlah data AIS yang bersih, yaitu sebanyak 73.6 juta dari 661.8 juta *record*. Selanjutnya, data yang bersih ini akan digunakan untuk dilakukan analisis lebih lanjut.



Gambar 2. Persentase data AIS setelah filter kedua berdasarkan status navigasi kapal




Gambar 3. Persentase data AIS setelah filter keempat berdasarkan tipe kapal

B. Indikator yang Terbentuk dari Data AIS

Perbandingan Pola Indikator AIS dengan Ekspor Impor

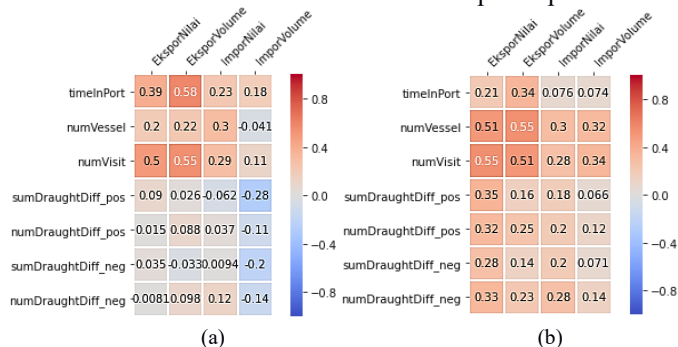
Dari data AIS yang telah bersih, dibentuk indikator yang terkait statistik ekspor impor. Indikator yang terbentuk yaitu seperti pada TABEL III. Apabila *series* indikator tersebut dibandingkan polanya dengan *series* data ekspor impor pada periode Desember 2018 hingga Desember 2020, maka akan terlihat seperti Gambar 4.



Gambar 4. Plot *series* indikator AIS dan data ekspor impor dari Desember 2018 hingga Desember 2020

Terlihat bahwa indikator ‘timeInPort’, ‘numVessel’, dan ‘numVisit’ memiliki pola pergerakan yang sama dengan data ekspor. Sedangkan indikator ‘numDraughtDiff’ dan ‘sumDraughtDiff’ memiliki pola yang hampir sama pada data impor, terutama pada awal periode. Namun terdapat kenaikan yang tinggi untuk indikator ‘timeInPort’, ‘numDraughtDiff’, dan ‘sumDraughtDiff’ pada bulan Desember 2019, sedangkan pada data ekspor impor tidak memiliki pola tersebut.

Indikator terkait aktivitas ekspor impor dikembangkan dan diagregasi dari data AIS seperti yang sudah dijelaskan pada bab IV. Untuk mengetahui hubungan antara indikator AIS dengan data ekspor impor, maka dilakukan penghitungan nilai korelasi antara kedua variabel tersebut. Gambar 5 menunjukkan nilai korelasi Pearson antara data ekspor impor dengan indikator AIS pada tingkat pertumbuhannya. Terlihat bahwa dengan memfilter data AIS yang relevan dengan aktivitas ekspor impor, seperti pada TABEL V, mampu memberikan korelasi yang lebih baik antara indikator AIS dan data ekspor impor.



Gambar 5. Matriks korelasi indikator AIS dengan data ekspor impor (a) sebelum memfilter data AIS dan (b) setelah memfilter data AIS

Nilai korelasi yang positif menunjukkan bahwa tingkat pertumbuhan indikator AIS memiliki hubungan yang positif dengan data ekspor impor. Indikator AIS ‘numVisit’ dan ‘numVessel’ memiliki tingkat korelasi cukup kuat (≥ 0.50) dengan nilai dan volume ekspor, sedangkan terhadap nilai dan volume impor memiliki tingkat korelasi sedang (≥ 0.25). Dua indikator tersebut memiliki tingkat korelasi tertinggi jika dibandingkan indikator AIS lainnya.

Indikator AIS sebagai Variabel Prediktor

TABEL VI.
SIMULASI SELEKSI VARIABEL PREDIKTOR

Nama Parameter	Tanpa Seleksi	Permutation Importance	Stepwise Regression	Var. Sig	Korelasi
Nilai Ekspor	X1, X2, X3, X4, X6	X2, X6	X3	X1, X2, X3	X2, X3, X4, X6
Volume Ekspor	X1, X2, X3, X4, X6	X2, X3, X4, X6	X2	X3	X1, X2, X3, X4
Nilai Impor	X1, X2, X3, X5, X7	X1, X2, X7	X2	X1, X3	X2, X3, X5
Volume Impor	X1, X2, X3, X5, X7	X1	X3	X3	X2, X3

Semua indikator yang terbentuk dari data AIS digunakan sebagai variabel prediktor untuk memprediksi data ekspor impor. Beberapa simulasi seleksi variabel juga dilakukan terhadap indikator tersebut untuk menentukan variabel

prediktor yang tepat bagi model peramalan, seperti *permutation importance* model ANN, *stepwise regression*, variabel yang signifikan pada model ARIMA ($\alpha=0.05$), dan nilai korelasi yang lebih dari 0.25. Variabel prediktor yang terpilih untuk setiap simulasi tersebut dapat terlihat pada TABEL VI.

C. Hasil Peramalan Ekspor Impor dengan ANN dan ARIMA

Indikator yang telah dihasilkan akan dijadikan variabel prediktor untuk meramalkan nilai dan volume ekspor impor menggunakan model ANN dan ARIMA. Adapun nilai RMSE hasil prediksi model peramalan seperti terlihat pada TABEL VII. Berdasarkan TABEL VII, dapat terlihat bahwa model ANN memiliki nilai *error* yang lebih kecil daripada ARIMA jika digunakan untuk meramalkan nilai dan volume ekspor serta volume impor. Sedangkan untuk nilai impor, model ARIMA lebih cocok digunakan, karena menghasilkan nilai *error* yang lebih kecil.

Pada TABEL VII juga dapat terlihat bahwa terdapat beberapa variabel AIS yang tidak signifikan jika digunakan sebagai variabel prediktor pada model ARIMA, bahkan terdapat pula variabel yang tidak signifikan sama sekali. Pada model ANN, terdapat beberapa model yang ada indikasi *overfitting* pada model tersebut. Hal tersebut dapat dilihat dari nilai *error* pada data *train* yang kecil, namun memiliki selisih nilai *error* yang besar pada data *test*, terutama pada model ANN terhadap data impor.

TABEL VII.
NILAI RMSE HASIL PREDIKSI MODEL ANN DAN ARIMA

Variabel Respons	Variabel Prediktor	ANN		ARIMA	
		Train	Test	Train	Test
Nilai Ekspor	X1 ^a , X2 ^a , X3 ^a , X4, X6	0.1068 ^b	1.2118	0.3769	1.6388
	X2 ^a , X6 ^a	0.2934	0.9310	0.4905	1.4856
	X3 ^a	0.7223	0.7852^b	0.4569	1.2496^b
	X1 ^a , X2 ^a , X3 ^a	0.2020	1.3935	0.4334	1.4063
	X2, X3, X4, X6	0.4870	0.7950	0.3494 ^b	1.8891
	X1, X2, X3 ^a , X4, X6	1.1913	1.4106	0.7685 ^b	1.8301
Volume Ekspor	X2, X3 ^a , X4, X6	1.1937	1.3347	0.9694	1.9395
	X2 ^a	1.3341	1.2974	1.1668	1.2391^b
	X3 ^a	1.3618	1.2938	0.9768	1.7833
	X1, X2, X3 ^a , X4	1.0408^b	1.2305^b	0.7886	1.8389
	X1 ^a , X2, X3 ^a , X5, X7	0.0055^b	1.0299^b	0.4112 ^b	1.0004
	X1, X2, X7	0.0685	1.2387	0.7100	0.9077
Nilai Impor	X2	0.6839	1.4943	0.7173	0.9944
	X1 ^a , X3 ^a	0.3946	1.2611	0.5232	2.2097
	X2, X3 ^a , X5	0.3344	1.5844	0.5655	0.9061^b
	X1, X2, X3 ^a , X5, X7	0.0323 ^b	1.4515	0.6563	1.7721
	X1	0.8067	0.7581^b	0.5663 ^b	1.6655
	X3 ^a	0.7839	1.2394	0.7072	1.4441^b
Volume Impor	X3 ^a	0.7697	1.1988	0.7072	1.4441^b
	X2, X3 ^a	0.6436	1.4102	0.6822	1.6684

a. Variabel prediktor yang signifikan dalam model ARIMA

b. Nilai terkecil untuk setiap variabel respons

Nilai RMSE pada data *train* sebesar 0.0055, sedangkan pada data *test* sebesar 1.0299. Hal tersebut menjadikan model ARIMA dipilih sebagai model peramalan pada nilai impor, selain juga karena memiliki nilai *error* yang lebih kecil. Namun untuk model yang lain, model ANN memiliki nilai *error* yang lebih kecil sehingga lebih unggul daripada ARIMA.


Model terbaik dipilih berdasarkan nilai *error* terkecil yang dihasilkan pada data *test*. Variabel prediktor yang digunakan pada setiap model dan parameter model terbaik ditunjukkan pada TABEL VIII. Dapat terlihat bahwa seleksi variabel yang

terbaik yaitu menggunakan *stepwise regression*, nilai korelasi, dan *permutation importance*. Model ANN dipilih untuk meramalkan nilai ekspor, volume ekspor, dan volume impor. Sedangkan untuk nilai impor menggunakan model ARIMA.

TABEL VIII.
PARAMETER MODEL TERBAIK DAN VARIABEL PREDIKTOR YANG DIGUNAKAN

Variabel Respons	Seleksi Variabel	Variabel Prediktor	Parameter Model Terbaik
Nilai ekspor	Stepwise regression	numVisit (X3)	hidden_layer: [75, 50, 100], 'activation': 'leaky_relu', 'learning_rate': 0.7348, 'momentum': 0.5662
Volume ekspor	Nilai korelasi	timeInPort (X1), numVessel (X2), numVisit (X3), numDraughtDiff positif (X4)	hidden_layer: [60, 9, 69], 'activation': 'leaky_relu', 'learning_rate': 0.1513, 'momentum': 0.4370
Nilai impor	Nilai korelasi	numVessel (X2), numVisit (X3), numDraughtDiff negatif (X5)	ARIMA (2,0,0)
Volume impor	Permutation importance	timeInPort (X1)	hidden_layer: [62, 88, 91], 'activation': 'leaky_relu', 'learning_rate': 0.9829, 'momentum': 0.5484

Model yang terbaik yang telah diperoleh digunakan untuk melakukan peramalan setiap variabel respons. Adapun nilai hasil peramalan untuk lima bulan jika dibandingkan dengan nilai aktual seperti terlihat pada Gambar 6. Terlihat bahwa pada bulan Desember 2020, semua hasil prediksi memiliki arah yang berbeda. Pada Gambar 6 menunjukkan hasil peramalan yang memiliki pola yang hampir sama dan *error* yang kecil, yaitu peramalan terhadap nilai impor. Sedangkan terhadap data ekspor, hasil peramalan tidak terlalu sama. Karena model peramalan nilai impor menggunakan ARIMA, maka dapat dikatakan bahwa model ARIMA dapat menghasilkan pola peramalan yang lebih baik daripada ANN, terutama pada nilai impor dengan indikator AIS sebagai variabel prediktor.



Gambar 6. Plot prediksi yang polanya hampir sama dan *error* kecil

VI. KESIMPULAN DAN SARAN

Berdasarkan hasil penelitian, dapat disimpulkan bahwa data AIS dapat digunakan untuk membentuk indikator terkait statistik ekspor impor. Dengan melakukan proses *cleaning* yang tepat, indikator yang terbentuk dari data AIS dapat memiliki pola hubungan yang lebih baik dengan statistik ekspor impor. Adapun indikator yang terbentuk yaitu waktu kapal di pelabuhan, jumlah unik kapal, jumlah kunjungan kapal, dan jumlah serta besaran perubahan sarat air kapal. Indikator AIS juga dapat digunakan sebagai variabel prediktor untuk meramalkan data ekspor impor. Model ANN merupakan model terbaik untuk meramalkan nilai ekspor, volume ekspor, dan volume impor. Sedangkan untuk nilai impor menggunakan metode peramalan ARIMA. Model ANN lebih unggul karena memberikan nilai *error* yang kecil untuk tiga dari empat statistik ekspor impor, sedangkan model ARIMA memberikan

pola peramalan yang lebih baik daripada model ANN pada statistik nilai impor.

Adapun saran untuk penelitian selanjutnya yaitu,

1. Menggunakan rentang data AIS dan data ekspor impor yang lebih panjang, supaya dapat mengenali pola ekspor impor periode sebelum-sebelumnya.
2. Menggunakan data pelabuhan Indonesia yang sama dengan cakupan data statistik ekspor impor.
3. Pengolahan atau *cleaning* data AIS perlu dikaji atau dikembangkan lebih lanjut.
4. Membuat indikator AIS baru dan indikator dengan waktu yang lebih spesifik, seperti mingguan atau bahkan harian.

DAFTAR PUSTAKA

- [1] R. Adland, H. Jia dan S. P. Strandenes, "Are AIS-based trade volume estimates reliable? The case of crude oil exports," *Maritime Policy & Management*, 2017.
- [2] S. Arslanalp, M. Marini dan P. Tumbarello, "Big Data on Vessel Traffic: Nowcasting Trade Flows in Real Time," *IMF Working Paper*, December 2019.
- [3] D. A. Cerdeiro, A. Komaromi, Y. Liu dan M. Saeed, "World Seaborne Trade in Real Time: A Proof of Concept for Building AIS-based Nowcasts from Scratch," *IMF Working Paper*, May 2020.
- [4] UN Global Working Group, "United Nations Global Platform: Data for the World," UN Global Working Group, 2019.
- [5] Badan Pusat Statistik, "Perdagangan Luar Negeri," November 2020. [Online]. Available: <https://www.bps.go.id>.
- [6] Y. Rahkmawati, I. M. Sumertajaya dan M. N. Aidi, "Evaluation of Accuracy in Identification of ARIMA Models Based on Model Selection Criteria for Inflation Forecasting with the TSClust Approach," *International Journal of Scientific and Research Publications*, vol. 9, no. 9, pp. 439-443, 2019.
- [7] J. Neves dan P. Cortez, "Combining Genetic Algorithms, Neural Networks and Data Filtering for Time Series Forecasting," dalam *IMACS International Conference on Circuits, Systems and Computers (IMACS-CSC'98)*, Piraeus, Greece, 1998.
- [8] D. Zissis, E. K. Xidias dan D. Lekkas, "Real-time vessel behavior prediction," *Evolving Systems*, no. 7, pp. 29-40, 2016.
- [9] International Maritime Organization, "Regulations for carriage of AIS," 26 Maret 2021. [Online]. Available: <https://www.imo.org>.
- [10] I. K. Ahani, M. Salari dan A. Shadman, "Statistical models for multi-step-ahead forecasting of fine particular matter in urban areas," *Atmospheric Pollution Research*, vol. 10, no. 3, pp. 689-700, 2019.
- [11] F. Ahmed, Y. Cui, Y. Fu dan W. Chen, "A Graph Neural Network Approach for Product Relationship Prediction," *ASME IDETC*, 2021.
- [12] R. Nooraeni, P. N. Sari dan N. P. Yudho, "Using Google trend data as an initial signal Indonesia unemployment rate," dalam *ISI World Statistics Congress*, Kuala Lumpur, 2019.
- [13] J. Han, M. Kamber dan J. Pei, *Data mining: concepts and technique*, San Fransisco: Morgan Kaufman Publisher, 2006.
- [14] J. Torres, D. Gutiérrez-Avilés, A. Lora dan F. Martínez-Álvarez, "Random Hyper-parameter Search-Based Deep Neural Network for Paper Consumption Forecasting," *IWANN*, 2019.
- [15] E. S. Raymond, "AIVDM/AIVDO protocol decoding," Januari 2021. [Online]. Available: <https://gpsd.gitlab.io/gpsd/AIVDM.html>. [Diakses Juni 2021].
- [16] A. Noyvirt, "Faster Indicators of UK Economic Activity: Shipping," *Data Science Campus*, 2019.
- [17] USCG, "Definition - Vessel Restricted in Her Ability to Maneuver," USCG Navigation Center, Januari 2021. [Online]. Available: <https://www.navcen.uscg.gov>. [Diakses Juni 2021].