

**ESTIMASI LUAS AREA TANAM PADI DENGAN DEEP
LEARNING PADA CITRA SATELIT RESOLUSI MENENGAH
SENTINEL-2 DAN LANDSAT-8**

(Studi Kasus di Kabupaten Nganjuk, Jawa Timur)

**TERRY DEVARA TRI SAADI
221710028**

**PROGRAM STUDI : KOMPUTASI STATISTIK
PROGRAM DIPLOMA IV
PEMINATAN : SAINS DATA**



**POLITEKNIK STATISTIKA STIS
JAKARTA
2021**

**ESTIMASI LUAS AREA TANAM PADI DENGAN DEEP
LEARNING PADA CITRA SATELIT RESOLUSI MENENGAH
SENTINEL-2 DAN LANDSAT-8**

(Studi Kasus di Kabupaten Nganjuk, Jawa Timur)

SKRIPSI

**Diajukan sebagai Salah Satu Syarat untuk Memperoleh Sebutan Sarjana
Sains Terapan pada Politeknik Statistika STIS**

Oleh

TEERRY DEVARA TRI SAADI

221710028



**POLITEKNIK STATISTIKA STIS
JAKARTA
2021**

PERNYATAAN
Skripsi dengan Judul
ESTIMASI LUAS AREA TANAM PADI DENGAN DEEP
LEARNING PADA CITRA SATELIT RESOLUSI MENENGAH
SENTINEL-2 DAN LANDSAT-8
(Studi Kasus di Kabupaten Nganjuk, Jawa Timur)

Oleh
TERRY DEVARA TRI SAADI
221710028

adalah benar-benar hasil penelitian sendiri dan bukan hasil plagiat atau hasil karya orang lain. Jika di kemudian hari diketahui ternyata skripsi ini hasil plagiat atau hasil karya orang lain, penulis bersedia skripsi ini dinyatakan tidak sah dan sebutan Sarjana Sains Terapan dicabut atau dibatalkan.

Jakarta, Juli 2021

TERRY DEVARA TRI SAADI

**ESTIMASI LUAS AREA TANAM PADI DENGAN DEEP
LEARNING PADA CITRA SATELIT RESOLUSI MENENGAH
SENTINEL-2 DAN LANDSAT-8
(Studi Kasus di Kabupaten Nganjuk, Jawa Timur)**

**Oleh:
TERRY DEVARA TRI SAADI
221710028**

Tim Penguji

Penguji I

Penguji II

Yunarso Anang Ph.D.
NIP 19700616 198812 1 001

Firdaus, M.B.A.
NIP 19720526 199112 1 001

Mengetahui/Menyetujui

Program Diploma IV
Ketua Program Studi Komputasi Statistik

Pembimbing

Yunarso Anang, Ph.D.
NIP 19700616 198812 1 001

Dr. Eng. Arie Wahyu Wijayanto,
S.S.T. M.T.
NIP 19851222 200902 1 002

PRAKATA

Syukur Alhamdulillah penulis ucapkan ke hadirat Allah SWT, akhirnya hanya berkat pertolongan-Nya penulis dapat menyelesaikan skripsi yang berjudul “Estimasi Luas Area Tanam Padi dengan Deep Learning pada Citra Satelit Resolusi Menengah Sentinel-2 dan Landsat-8, Studi Kasus di Kabupaten Nganjuk, Jawa Timur”. Penulis juga mengucapkan terima kasih kepada:

1. Ibu Dr. Erni Tri Astuti selaku Direktur Politeknik Statistika STIS,
2. Bapak Dr. Eng. Arie Wahyu Wijayanto, S.S.T. M.T. selaku dosen pembimbing yang telah membimbing dengan penuh kesabaran dalam penyusunan skripsi ini,
3. Bapak Yunarso Anang Ph.D. dan Firdaus, M.B.A. selaku dosen penguji yang telah memberikan koreksi dan saran.
4. Orang tua, serta saudara-saudara penulis di Kabupaten Nganjuk yang selalu memberikan dukungan dan doa kepada penulis,
5. Teman-teman satu bimbingan, satu daerah, dan angkatan 59 serta semua pihak yang telah memberi dukungan dalam penulisan skripsi ini.

Penulis menyadari bahwa skripsi ini masih jauh dari kesempurnaan baik isi maupun susunannya. Penilaian obyektif dari penulisan skripsi ini diperlukan juga dari pembaca yang mencermatinya dengan baik. Oleh karena itu, saran dan kritik yang membangun sangat penulis harapkan demi perbaikan skripsi ini.

Akhirnya, semoga skripsi ini dapat bermanfaat bagi banyak pihak.

Jakarta, Juli 2021

TERRY DEVARA TRI SAADI

ABSTRAK

Terry Devara Tri Saadi, “Estimasi Luas Area Tanam Padi dengan Deep Learning pada Citra Satelit Resolusi Menengah Sentinel-2 dan Landsat-8, Studi Kasus di Kabupaten Nganjuk, Jawa Timur”.

viii+54

Pada tahun 2018, Badan Pusat Statistik (BPS) telah memperkenalkan metode Kerangka Sampel Area (KSA) untuk melakukan estimasi area produksi padi, di mana prosesnya masih membutuhkan sumber daya manusia dan biaya yang besar. Penelitian ini membahas mengenai pemanfaatan data penginderaan jauh, khususnya citra satelit Sentinel-2 dan Landsat-8, sebagai pendekatan alternatif yang lebih murah dari sisi biaya dan tenaga. Penelitian ini berfokus pada penentuan fitur pita spektral dan indeks komposit citra dengan pemanfaatan metode *deep learning* untuk mendeteksi area tanam padi di Kabupaten Nganjuk, Jawa Timur. Selain itu penelitian ini bertujuan untuk membuat model pengklasifikasian terbaik, sekaligus melakukan estimasi area tanam padi. Hasil penelitian menunjukkan model CNN memberikan hasil terbaik dengan nilai f1-score sebesar 97,03%.

Kata Kunci: penginderaan jauh, deteksi padi, *deep learning*

DAFTAR ISI

	Halaman
PRAKATA	i
ABSTRAK	ii
DAFTAR ISI	iii
DAFTAR TABEL	iv
DAFTAR GAMBAR	v
DAFTAR LAMPIRAN	vi
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Identifikasi dan Batasan Masalah	2
1.3 Tujuan Penelitian	3
1.4 Keterbatasan Penelitian	3
BAB II KAJIAN PUSTAKA	7
2.1 Landasan Teori	7
2.2 Penelitian Terkait	13
2.3 Kerangka Pikir	16
BAB III METODOLOGI	17
3.1 Ruang Lingkup Penelitian	17
3.2 Metode Pengumpulan Data	18
3.3 Metode Analisis	22
BAB IV HASIL DAN PEMBAHASAN	25
4.1 Identifikasi Fitur Terbaik Penciri Area Tanam Padi	25
4.2 Identifikasi Model Terbaik Pengenalan Lahan Padi	27
.....	33
4.3 Estimasi Luas Lahan Tanam Padi	33
BAB V KESIMPULAN DAN SARAN	35
5.1 Kesimpulan	35
5.2 Saran	35
DAFTAR PUSTAKA	37
LAMPIRAN	43
RIWAYAT HIDUP	48

DAFTAR TABEL

No.Tabel	Judul Tabel	Halaman
1	Tabel literatur dari penelitian terkait	14
2	Jumlah sampel dalam piksel dari Sentinel 2 MSI dan Landsat 8	19
3	Daftar indeks komposit yang digunakan dan persamaannya.....	20
4	Band Spectral dari Sentinel 2 dan Landsat 8	21
5	Hasil 10-fold cross validation dari semua model dengan menggunakan Sentinel 2 resolusi 10m, Sentinel 2 resolusi 30m, dan Landsat 8 pada kombinasi semua kelas.	30
6	Perbandingan performa model deep learning menggunakan 10-fold cross validation	31
7	Perbandingan f1-score masing-masing kelas untuk tiap model.....	32

DAFTAR GAMBAR

No. Gambar	Judul Gambar	Halaman
1	Ilustrasi perbandingan efek resolusi spasial pada daerah yang diberi label sawah.....	5
2	Kerangka Pikir	16
3	Citra (a) Landsat 8 dan (b) Sentinel 2 yang digunakan.....	17
4	Tampilan sampel dari masing-masing kelas,	19
5	Alur kerja (<i>workflow</i>) penelitian	24
6	Heatmap masing-masing band dan indeks dari Sentinel 2 (atas) dan Landsat 8 (bawah) terhadap masing-masing kelas.....	26
7	Confusion Matrix dari CNN1D pada Sentinel 2	33
8	Visualisasi hasil segmentasi citra satelit sebagian wilayah Kabupaten Nganjuk.	34

DAFTAR LAMPIRAN

No. Lampiran	Judul Lampiran	Halaman
1	Model Random Forest	43
2	Model Extra Trees	43
3	Model Decision Tree	44
4	Model Logistic Regression	45
5	Model Linear Support Vector Machine	45
6	Model AdaBoost	45
7	Model XGBoost	46
8	Multi Layer Perceptron	46
9	Model Convolutional Neural Network	47

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Beras telah lama menjadi sumber makanan utama bagi rakyat Indonesia. Meskipun begitu, berdasarkan publikasi Luas Panen dan Produksi Panen Padi dari Badan Pusat Statistik (BPS), pada 2019, luas panen padi Indonesia diperkirakan sebesar 10,68 juta hektar atau mengalami turun 700,05 ribu hektar (6,15%) dibanding tahun 2018 (BPS-Statistics Indonesia, 2020). Selain itu, pada 2019, produksi padi Indonesia diperkirakan sebesar 54,60 juta ton GKG atau mengalami penurunan sebanyak 4,60 juta ton (7,76) dibanding tahun 2018 (BPS-Statistics Indonesia, 2020). Hal ini mendorong perlunya dilakukan monitoring area tanam dan produksi pangan untuk mewujudkan *goals* ke dua dari *Sustainable Development Goals (SDGs)*.

Memonitoring tanaman pangan telah dilakukan oleh BPS melalui Kerangka Samplel Area (KSA) yang dilakukan dengan survei lapangan terhadap titik-titik pengamatan dalam sampel segmen (BPS-Statistics Indonesia, 2015). Meskipun merupakan metode estimasi dengan akurasi yang baik, KSA memerlukan sumber daya yang cukup besar. Selain itu, penggunaan KSA juga masih rentan pada kondisi kahar dan *remote area*. Hal ini memberikan keterbatasan untuk dapat mencakup seluruh wilayah Indonesia dalam periode update yang cepat sesuai kebutuhan monitoring waktu tanam padi.

Di sisi lain, data penginderaan jauh dapat diperoleh dengan mudah dan dapat digunakan di berbagai bidang. Beberapa bidang yang telah memanfaatkan data

penginderaan jauh sendiri di antaranya adalah klasifikasi tutupan lahan (Ienco, Gaetano, Dupaquier, & Maurel, 2017), prediksi kemiskinan (Jean, Burke, Xie, et al., 2016), pemetaan area terbakar (Fitriana, Suwarsono, Kusratmoko, & Supriatna, 2020), klasifikasi tanaman (Kussul, Lemoine, Gallego, et al., 2016). Penelitian ini berfokus pada estimasi luas area tanam padi dengan deep learning di kabupaten Nganjuk sebagai salah satu kabupaten utama penghasil padi di Jawa Timur di mana separuh wilayahnya digunakan untuk menanam padi.

1.2 Identifikasi dan Batasan Masalah

Selama masa pandemi berlangsung, banyak dilakukan pembatasan mobilitas seperti Pembatasan Sosial Berskala Mikro (PSBM), maupun Pembatasan Sosial Berskala Besar (PSBB). Pembatasan sosial ini ikut memiliki dampak pada KSA karena selama pembatasan sosial tersebut, petugas tidak dapat mengunjungi daerah yang digunakan sebagai segmen KSA. Sebagai dampaknya, respons rate KSA pada awal masa pandemi mengalami dampak yang cukup besar dari yang awalnya di atas 95%, turun menjadi 30% untuk yang paling rendah, dan 85% sebagai respons rate paling tinggi.

Penelitian ini juga hanya berfokus pada penggunaan metode *deep learning* dalam mendeteksi area tanam padi. Luas area tanam digunakan sebagai variabel utama karena untuk variabel produksi, diperlukan klasifikasi hingga ke fase tanam padi. Sebelumnya, sudah terdapat penelitian dari Triscowati dkk. (Triscowati, Sartono, Kurnia, Dirgahayu, & Wijayanto, 2020) yang berfokus pada penggunaan data multi temporal untuk melakukan klasifikasi fase tanam dan luas panen. Hanya

saja, dalam penelitian ini hanya digunakan metode *random forest* dan citra Landsat 8 tanpa pembandingan lain. Penelitian ini diharapkan dapat digunakan untuk melengkapi penelitian dari Triscowati dan mampu memberikan performa yang lebih baik dalam mengklasifikasikan fase tanam dan mengestimasi luas panen padi.

1.3 Tujuan Penelitian

Tujuan yang ingin dicapai dalam penelitian ini adalah

1. Mengidentifikasi fitur terbaik untuk mengenali citra lahan tanam padi.
2. Mengidentifikasi model terbaik untuk pengenalan citra dan estimasi luas lahan tanam padi.
3. Melakukan estimasi luas lahan tanam padi.

1.4 Keterbatasan Penelitian

Keterbatasan pertama dari penelitian ini adalah, belum adanya data *official* yang benar-benar membagi suatu wilayah berdasarkan tutupan lahan hingga ke tingkatan koordinat. Sebagai akibatnya, semua penelitian yang berkaitan dengan tutupan lahan menggunakan citra satelit, keakuratannya hanya sebatas akurasi berdasar data yang digunakan dan bukan dari perbandingan dengan data *official*. Dalam penelitian ini, dilakukan pemeriksaan lapangan (*ground check*) untuk memastikan keabsahan label yang digunakan.

Batasan kedua adalah terkait dengan penggunaan data KSA untuk penelitian. Jumlah segmen yang digunakan dan area yang terkover dalam KSA terlalu kecil

bila ingin digunakan sebagai data untuk *machine learning* dan *deep learning*, selain itu akan ada beberapa jenis tutupan lahan yang tidak termasuk dalam daerah yang dijadikan segmen. Hal ini akan berpengaruh besar terhadap performa model karena model membutuhkan informasi mengenai semua kelas yang ada. Selain itu, KSA menggunakan sub segmen dengan luas 100m^2 di mana semua objek yang berada pada daerah tersebut digeneralisir berdasarkan objek apa yang ada di titik pusat sub segmen. Sementara citra Sentinel 2 dan Landsat 8 memiliki resolusi spasial sebesar 10m^2 dan 30m^2 . Bila data KSA digunakan begitu saja, akan ada objek lain yang ikut diberi label suatu kelas (misal rumah diberi label sawah karena pada titik pusat sub segmen terdapat sawah). Untuk mempermudah pemahaman, ilustrasi perbandingan efek resolusi spasial untuk mendeteksi sawah dapat dilihat pada Gambar 1.



Contoh peta segmen

$10m^2$



$30m^2$

$100m^2$

Gambar 1. Ilustrasi perbandingan efek resolusi spasial pada daerah yang diberi label sawah.

(...sengaja dikosongkan...)

BAB II

KAJIAN PUSTAKA

2.1 Landasan Teori

Penginderaan Jauh

Berdasarkan *United States Geological Survey* (USGS), *remote sensing* atau penginderaan jauh, merupakan proses untuk mendeteksi dan mengamati karakter fisik suatu area dengan menghitung radiasi yang dipantulkan dari kejauhan (pada umumnya menggunakan Satelit atau Pesawat). Kamera khusus digunakan untuk mengambil foto atau citra dari kejauhan yang dapat membantu peneliti mengamati atau “*sense*” segala hal mengenai Bumi.

Citra *Multispectral*

Citra *multispectral* merupakan citra yang diambil menggunakan sensor khusus untuk bisa mendapatkan lebih banyak informasi dibandingkan apa yang ditangkap mata manusia biasa. Citra *multispectral* menangkap informasi mengenai dunia melalui dimensi yang lebih luas bila dibandingkan perspektif mata manusia (mata manusia hanya menangkap cahaya dengan ukuran 450nm – 650nm, band pada citra *multispectral* bisa berukuran 800nm hingga 2000nm).

Machine Learning

Istilah *machine learning* diperkenalkan oleh Arthur Samuel pada 1959 sebagai “Suatu bidang yang memungkinkan komputer untuk belajar, tanpa perlu diprogram secara eksplisit. Dalam sebuah *paper* yang terdapat pada *IBM Journal of Research and Development*, ia menuliskan “memprogram komputer untuk belajar dari pengalaman akan menghilangkan kebutuhan untuk melakukan pemrograman secara detail”(Samuel, 1959). Dengan memanfaatkan metode statistik, algoritma dapat dilatih untuk melakukan klasifikasi maupun prediksi.

Deep Learning

Deep learning merupakan metode yang memberikan kemampuan pada komputer untuk belajar dari pengalaman dan memahami dunia dalam sebuah konsep hierarki, di mana masing-masing konsep dijelaskan melalui relasinya terhadap konsep yang lebih sederhana. Dengan mengumpulkan pengetahuan dari pengalaman tersebut, kebutuhan akan operator manusia untuk menjelaskan semua pengetahuan yang diperlukan komputer dapat dihilangkan. Hierarki dari konsep memungkinkan komputer untuk mempelajari konsep yang rumit dengan menyusunnya sebagai konsep yang lebih sederhana. Karena ketika sebuah grafik digunakan untuk menggambarkan susunan konsep tersebut terbentuk grafik yang dalam (*deep*) dengan banyak layer, pendekatan ini disebut *deep learning*(Goodfellow, Bengio, & Courville, 2016).

Computer Vision

Berdasarkan *International Business Machine Corporation* (IBM), *computer vision* merupakan suatu bidang kecerdasan buatan yang memungkinkan komputer dan sistem untuk memperoleh suatu informasi yang memiliki arti dari sebuah citra, video, maupun input visual lainnya, dan mengambil keputusan atau memberikan usulan berdasarkan informasi tersebut. Pada 1982, David Marr memperkenalkan algoritma yang membuat mesin dapat mendeteksi, ujung, sudut, kurva dan bentuk dasar lainnya. Kemudian Kunihiro Fukushima mengembangkan jaringan sel yang terdiri dari *convolutional layers* dalam sebuah *neural network* yang dapat mengenali pola (Fukushima, 1988).

Decision Tree

Istilah *Classification and Regression Tree* (CART) (Breiman, Friedman, Olshen, & Stone, 1984) merujuk pada penggunaan *decision tree* dalam hal predictive modeling dengan menggunakan, baik analisa *classification tree* maupun *regression tree*, dengan menciptakan *decision tree*, di mana masing-masing *node* membuat keputusan biner untuk membedakan kelas satu sama lain.

Support Vector Machine

Support Vector Machine (SVM) (Drucker, Surges, Kaufman, Smola, & Vapnik, 1997) merupakan metode klasifikasi yang membuat batasan non linear dengan menciptakan batasan linear dalam ruang fitur yang lebih besar dan telah dimodifikasi.

Ensemble Bagging Methods

Bagging atau *bootstrap*, merupakan pendekatan yang digunakan untuk mengurangi varians dari suatu fungsi estimasi. Dalam algoritma dengan varians tinggi dan bias rendah seperti *trees*, *bagging* menunjukkan performa yang cukup baik. Dalam regresi, *regression trees* yang sama dilakukan *fitting* beberapa kali untuk membuat *bootstrap* sampel dari *training* dan mengambil rata-rata hasilnya. Pada klasifikasi, voting dilakukan beberapa *tree* untuk kelas yang ingin diprediksi (Hastie, Tibshirani, & Friedman, 2013).

Random Forest

Random forest (Breiman, 2001) merupakan metode perubahan dari teknik *bagging* yang mengumpulkan *library trees* yang ber-dekorelasi lalu dirata-ratakan. Walaupun secara umum mirip dengan *bagging* dari sisi performa, *random forest* lebih mudah dari segi *training* dan *tuning*. Maka dari *random forest* menjadi populer dan banyak diimplementasikan dalam berbagai *package*.

Extra Trees

Extremely randomized trees (Geurts, Ernst, & Wehenkel, 2006), atau dikenal juga sebagai *extra trees*, pada dasarnya mencakup pemilihan atribut maupun titik potong dengan sangat random, pada saat melakukan *splitting* dari suatu *node* pada *tree*. Pada kasus yang ekstrem, *trees* dibuat dibangun menggunakan arsitektur yang independen dari nilai *output* sampel *learning*. Tuning dari

randomisation atau keacakan dapat dilakukan dengan pemilihan parameter yang sesuai.

Ensemble Boosting Methods

Inti dari *boosting* adalah untuk membuat sebuah “komite” yang berukuran sangat besar, dengan menggabungkan hasil dari model klasifikasi “lemah” yang berjumlah sangat banyak. Model klasifikasi “lemah” adalah Metode klasifikasi dengan tingkatan *error* tidak berbeda jauh dari tebakan acak. Dengan menjalankan algoritma klasifikasi “lemah” ini secara terus menerus pada data yang terus dimodifikasi, didapatkan kumpulan model klasifikasi “lemah”. Prediksi akhir dibuat berdasarkan suara terbanyak dari hasil prediksi model klasifikasi “lemah” tersebut (Hastie et al., 2013). Dalam penelitian ini, digunakan dua *Ensemble Boosting Methods* yang paling populer, AdaBoost dan XGBoost.

Multi Layer Perceptron (MLP)

Multilayer perceptron merupakan model *neural network* dengan beberapa *hidden layer*, dan neuron antar layer yang bersebelahan saling terhubung (Jiang, He, Long, et al., 2018). Penggunaan *hidden layer* yang sedikit mengakibatkan akurasi menjadi rendah. Penambahan jumlah layer akan menyebabkan peningkatan waktu pemrosesan sementara akurasi belum tentu meningkat. Cara kerja dari MLP sendiri lebih berfokus pada mengingat pola yang ada, sehingga secara umum performanya kurang baik pada data yang belum pernah dilihat sebelumnya.

Convolutional Neural Network (CNN)

CNN merupakan model *deep learning multilayer* dengan menggunakan sebuah *neural network* melalui proses *training end to end* dari nilai pixel mentah menjadi output terklasifikasi. Dengan memanfaatkan training data berukuran besar dan pengimpelentasian GPU yang efisien, CNN telah melampaui performa dari metode konvensional dalam *computer vision*, termasuk *image classification*, *object detection*, *scene labelling*, dan *face recognition* (Hu, Huang, Wei, Zhang, & Li, 2015).

Grid Search

Grid search adalah proses hyper parameter (parameter yang tidak dipelajari secara langsung oleh estimator) tuning atau pemilihan parameter terbaik. Hal ini dilakukan dengan membuat daftar kombinasi yang mungkin digunakan dari nilai parameter yang diberikan. Kombinasi tersebut yang menjadi kandidat dari parameter yang diujikan pada model. Hanya kombinasi yang dapat memberikan performa terbaik berdasarkan matriks evaluasi yang diberikan akan disimpan (Pedregosa, Varoquaux, Gramfort, et al., 2019).

K-Fold Cross Validation

Dalam k-fold cross validation (cv), data dibagi menjadi k bagian dengan ukuran yang (kurang-lebih) sama. Model kemudian dilatih sebanyak k kali dengan meninggalkan satu bagian dari data sebagai data training, dan bagian yang

ditinggalkan tersebut digunakan sebagai data testing. Kekurangan dari metode ini adalah training set yang digunakan tidak benar-benar independent (Borra & Di Ciaccio, 2010).

2.2 Penelitian Terkait

Terdapat beberapa penelitian sebelumnya dengan tujuan klasifikasi penggunaan lahan. Sebagaimana bisa dilihat dari tabel literatur di Tabel 1. Masih terbatasnya jumlah penelitian pada bidang penginderaan jauh di Indonesia yang memanfaatkan teknologi *machine learning* untuk melakukan klasifikasi lahan padi. Sementara itu, hingga saat ini, sepanjang pengetahuan dan pencarian penulis, pemanfaatan metode *deep learning* yang secara luas terbukti lebih unggul di bidang *computer vision* belum dipergunakan untuk mendeteksi lahan padi di Indonesia.

Tabel 1. Tabel literatur dari penelitian terkait


No	Pengarang, Tahun	Tujuan	Fitur dan Metode	Sumber Data	Lokasi Studi
(1)	(2)	(3)	(4)	(5)	(6)
1	(I. M. Parsa, Dirgahayu, Harini, & S, 2020)	Identifikasi konversi lahan sawah akibat pembangunan jalan bebas hambatan	Transformasi indeks vegetasi dan overlay (tumpang-susun) data	Landsat 7 (Terbuka), Landsat 8 (Terbuka), SPOT 6 (Tertutup), SPOT 7 (Tertutup)	Subang, Jawa Barat
2	(M. Parsa, Dirgahayu, Harini, et al., 2020)	Memperoleh parameter optimal untuk model klasifikasi lahan tanam padi berdasar data multi temporal	Transformasi indeks vegetasi	Landsat 8 (Terbuka)	Jawa Barat dan Sulawesi Selatan
3	(Rokhmatuloh, Supriatna, Pin, et al., 2019)	Pemetaan area tanam padi dengan citra multi spectral	Transformasi indeks vegetasi	Unmanned Aerial Vehicle (Tertutup)	Parakansalak , Sukabumi, Jawa Barat
4	(Widiatmaka, Ambarwulan, Santoso, et al., 2016)	Pemetaan lahan untuk mengevaluasi kecocokan lahan untuk tanaman padi	Supervised Classification menggunakan software ERDAS	SPOT 6 (Tertutup)	Subang, Jawa Barat
5	(Triscowati et al., 2020)	Mengembangkan model klasifikasi tanaman padi untuk data multi temporal	Transformasi indeks vegetasi, transformasi indeks air, dan Supervised Random Forest Clasification	Landsat 8 (Terbuka)	Banyuwangi, Jawa Timur

Tabel 1. Tabel literatur dari penelitian terkait (lanjutan)

No	Pengarang, Tahun	Tujuan	Fitur dan Metode	Sumber Data	Lokasi Studi
(1)	(2)	(3)	(4)	(5)	(6)
6	(Triscowati, Sartono, Kurnia, Domiri, & Wijayanto, 2019)	Mencari fitur multi temporal terbaik untuk klasifikasi fase tanaman padi	Transformasi indeks vegetasi, transformasi indeks air, dan Supervised Random Forest Clasification	Landsat 8 (Terbuka)	Banyuwangi, Jawa Timur
7	Penelitian ini	Mengidentifikasi fitur dan model terbaik untuk mengenali citra padi dan mengestimasi luas lahan tanam.	Transformasi indeks vegetasi, transformasi indeks air, machine learning dan deep dearning	Sentinel 2 (Terbuka), Landsat 8 (Terbuka)	Nganjuk, Jawa Timur

2.3 Kerangka Pikir

Penelitian ini didasari dari mahalnnya metode yang digunakan saat ini, baik dari segi biaya maupun tenaga, serta rentannya terhadap kondisi kahar seperti pandemi, dan *remote area*. Maka diajukan metode dengan memanfaatkan citra penginderaan jauh dan analisis menggunakan *machine learning* dan *deep learning*. Sebagai evaluasi, digunakan matriks *precision*, *recall*, dan *f1-score* dengan mempertimbangkan kondisi data yang digunakan memiliki *class imbalance*. Gambar 2 menunjukan ilustrasi kerangka pikir dengan mengikuti desain dari Polančič (Polančič, 2007) dan Berndtsson dkk. (Berndtsson, Hansson, Olsson, & Lundell, 2008)




Gambar 2. Kerangka Pikir

BAB III

METODOLOGI

3.1 Ruang Lingkup Penelitian

Penelitian ini dijalankan di kabupaten Nganjuk, Jawa Timur yang terletak pada latitude 7.6°S dan longitude 111.9333°E seperti yang dapat dilihat di gambar. Nganjuk memiliki wilayah seluas 1.182,64 km², di mana menurut BPS, pada tahun 2018, 65.539,42 hektar (55.42% wilayah) digunakan untuk bertanam padi dengan hasil produksi sebesar 395.385,12 ton GKG (BPS-Statistics Indonesia, 2019). Sektor Pertanian, Kehutanan, dan Perikanan sendiri merupakan penyumbang PDRB terbesar di kabupaten Nganjuk, yaitu sebesar 7.232 miliar rupiah, atau setara 29,18% dari PDRB kabupaten Nganjuk (BPS-Statistics Indonesia, n.d.).



Gambar 3. Citra (a) Landsat 8 dan (b) Sentinel 2 yang digunakan

3.2 Metode Pengumpulan Data

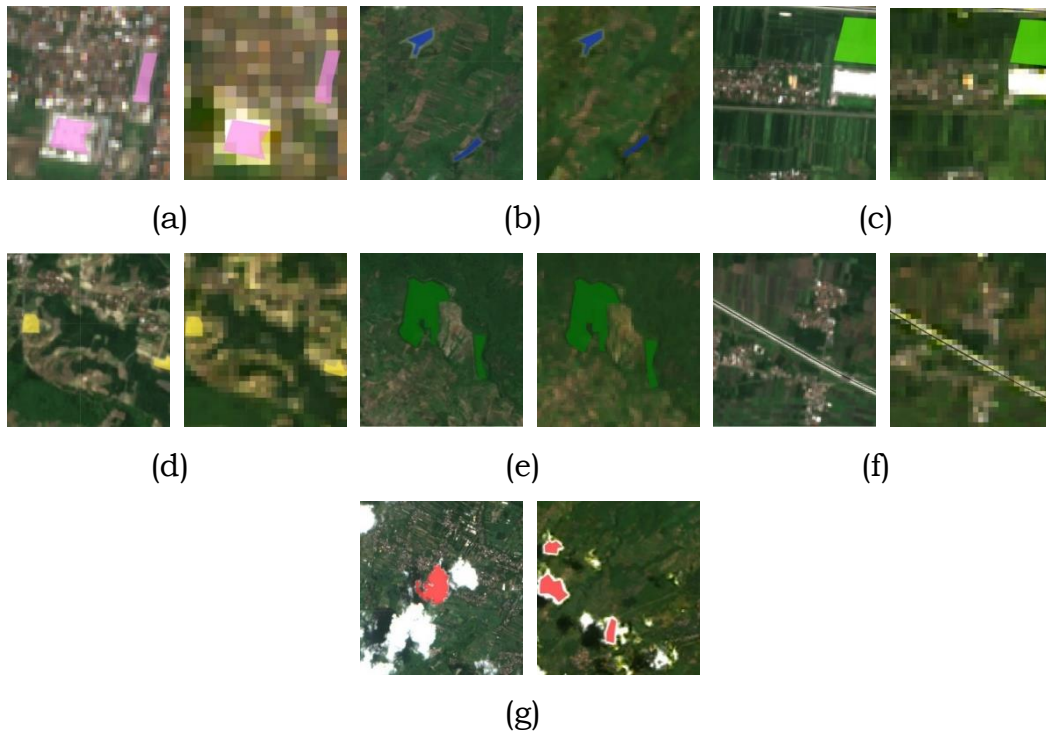
Pada penelitian ini, citra Sentinel-2 yang telah diproses menjadi level 2A yang diambil pada 14 Maret 2020 digunakan untuk menjalankan proses analisis dan evaluasi. Sampel yang digunakan dapat dilihat pada Tabel .

Pelabelan manual dilakukan dengan mengikuti tahapan yang dilakukan dalam penelitian penginderaan jauh. Berdasarkan P.Helber dkk. (Helber, Bischke, Dengel, & Borth, 2019), proses pelabelan pada data penginderaan jauh dilakukan dengan membandingkan citra satelit optik dengan *official label* dari data yang bersangkutan. Sebagai tambahan validasi, maka untuk wilayah sawah dilakukan identifikasi langsung ke lapangan oleh peneliti untuk memastikan bahwa yang dilabelkan memang sawah secara riil pada periode Desember 2020.

Dalam penelitian ini sendiri digunakan 7 label yang digunakan. Terbangun yang merupakan area pemukiman, dan gedung-gedung seperti mal, restoran, pabrik, dan bangunan lain. Air yang menunjukkan daerah yang permukaannya tertutup genangan air seperti sungai, danau, ataupun waduk. Sawah yang merupakan fokus penelitian ini, yaitu sawah yang ditanami padi. Bera yang merupakan daerah sawah yang sedang tidak ditanami ataupun sedang dalam masa transisi setelah panen. Hutan yang merupakan daerah perhutanan dan perkebunan. Tol yang merupakan jalan tol. Awan yang merupakan daerah yang sedang tertutup awan pada saat citra diambil. Awan dijadikan kelas tersendiri karena pada daerah tropis, tidak mungkin diambil citra satelit yang benar-benar bersih dari tutupan awan, maka untuk menghindari gangguan performa dari model yang disebabkan tutupan awan tersebut, awan dijadikan kelas tersendiri.

Tabel 2. Jumlah sampel dalam piksel dari Sentinel 2 MSI dan Landsat 8

	Sentinel 2	Landsat 8
	(1)	(2)
Terbangun	16.276	2.663
Air	4.904	825
Sawah	13.364	1.826
Bera	18.335	2.653
Hutan	17.891	2.302
Jalan Tol	3.138	796
Awan	14.847	1.639



Keterangan: Bagian kiri menunjukkan citra dari Sentinel 2, sementara bagian kanan menunjukkan citra dari Landsat 8. Kelas yang digunakan meliputi (a) terbangun, (b) air, (c) sawah, (d) bera, (e) hutan, (f) tol, dan (g) awan.

Gambar 4. Tampilan sampel dari masing-masing kelas,

Tabel 3. Daftar indeks komposit yang digunakan dan persamaannya

Indeks Komposit	Persamaan Band yang digunakan
(1)	(2)
NDVI	$\frac{(NIR - Red)}{(NIR + Red)}$
NDWI	$\frac{(Green - NIR)}{(Green + NIR)}$
NDBI	$\frac{(SWIR1 - NIR)}{(SWIR1 + NIR)}$
NDTI	$\frac{(SWIR1 - SWIR2)}{(SWIR1 + SWIR2)}$
EVI	$2,5 * \frac{(NIR - Red)}{(NIR + 6 * Red - 7,5 * Blue + 1)}$ <p>atau</p> $2,5 * \frac{(NIR - Red)}{(NIR + 2,4 * Red + 1)}$
BSI	$2,5 * \frac{((SWIR1 + Red) - (NIR + Green))}{((SWIR1 + Red) + (NIR + Green))}$

Keterangan: Band yang digunakan pada masing-masing satelit dapat dilihat di

Tabel 4

Fitur dasar yang digunakan dalam penelitian ini adalah band biru (Blue), hijau (Green), merah (Merah), *near-infrared* (NIR), serta *short wave infrared* (SWIR) 1 dan 2. Selain itu, beberapa indeks komposit yang merupakan kombinasi dari beberapa band juga digunakan, diantaranya *Normalized Difference Vegetation Index* (NDVI), dan *Enhanced Vegetation Index* (EVI) yang akan digunakan untuk membedakan antara sawah dan hutan. *Normalized Difference Water Index* (NDWI) untuk menunjukan daerah genangan air. *Normalized Difference Built-up Index* (NDBI), *Normalized Difference Tillage Index* (NDTI), dan *Bare Soil Index* (BSI) untuk membedakan antara area terbangun, bera, dan jalan tol.

Tabel 4. Band Spectral dari Sentinel 2 dan Landsat 8

Sentinel 2 Band		Wavelength (nm)	Bandwidth (nm)	Resolution (m)
(1)	(2)	(3)	(4)	(5)
1	(Aerosols)	443	20	60
2	(Blue)	490	65	10
3	(Green)	560	35	10
4	(Red)	665	30	10
5	(Red Edge 1)	705	15	20
6	(Red Edge 2)	740	15	20
7	(Red Edge 3)	783	20	20
8	(NIR)	842	11	10
8A	(Red Edge 4)	865	20	20
10	(Cirrus)	945	20	60
11	(SWIR 1)	1.375	30	60
12	(SWIR 2)	1.610	90	20

Landsat 8 Bands		Wavelength (nm)	Resolution (m)
(1)	(2)	(3)	(4)
1	(Ultra Blue)	0,435-0,451	30
2	(Blue)	0,452-0,512	30
3	(Green)	0,533-0,590	30
4	(Red)	0,636-0,673	30
5	(NIR)	0,851-0,879	30
6	(Shortwave Infrared 1)	1,566-1,651	30
7	(Shortwave Infrared 2)	2,107-2,294	30
10	(Brightness Temperature)	10,60-11,19	30
11	(Brightness Temperature)	11,50-12,51	30


3.3 Metode Analisis

Analisis fitur dilakukan secara deskriptif dengan menggunakan heatmap dari band dan indeks komposit pada masing-masing kelas. Analisis deskriptif digunakan karena pada penelitian ini digunakan metode deep learning dimana metode deep learning sendiri merupakan metode black box dalam artian walaupun kita dapat memahami fungsi dan cara kerja dari masing-masing layer, ketika layer tersebut saling terhubung, memahami cara kerja dari model akan menjadi sulit. Sebagai akibatnya, ketika layer baru ditambahkan ke sebuah model, atau susunan layer diubah, cara kerja model secara keseluruhan akan berubah. Hal inilah yang menyebabkan ketidak tersediaan metode statistik yang dapat digunakan untuk menentukan fitur terbaik dalam metode deep learning. Dari situlah digunakan analisis deskriptif dengan memanfaatkan heatmap untuk menentukan fitur terbaik.

Pemilihan model terbaik dibagi menjadi dua tahap. Tahap pertama adalah untuk menentukan model machine learning terbaik. Sementara tahap kedua dilakukan untuk membandingkan performa antara model deep learning dengan model machine learning terbaik. Performa model terbaik dinilai berdasarkan f1-score yang dihitung berdasarkan nilai presisi dan recall. F1-score dipilih karena penggunaan informasi yang bisa diperoleh dari akurasi sangat terbatas, selain itu, untuk melakukan deteksi area tanam padi, nilai presisi dan recall sama pentingnya, maka dipilihlah f1-score yang merupakan matriks evaluasi yang menyeimbangkan antara presisi dan recall. Jika terdapat keadaan dimana nilai f1-score dari dua model atau lebih sama, maka hal lain yang dijadikan pertimbangan adalah cost, baik dari segi kebutuhan komputasi, maupun waktu yang dibutuhkan. Untuk model machine learning, dilakukan hyper-parameter tuning atau proses pemilihan parameter

terbaik dengan menggunakan grid-search. Parameter serta arsitektur lengkap dari model dapat dilihat pada lampiran.

Citra satelit yang digunakan dalam penelitian diambil dengan memanfaatkan layanan Google Earth Engine (GEE). Citra yang diambil untuk Sentinel 2 adalah citra dengan Level 2-A dan untuk Landsat 8 adalah citra dengan Level 2 Surface Reflectance (SR). Hal ini berarti citra telah mengalami proses koreksi atmosfer (atmospheric correction) yang penting dalam analisis citra satelit dengan tanggal pengambilan berbeda. Karena keadaan atmosfer bumi mengalami perubahan tiap saatnya, meskipun tidak terdapat perubahan di permukaan, hasil tangkapan citra dapat menunjukkan perubahan karena perubahan di atmosfer tersebut. Koreksi atmosfer dapat mengurangi pengaruh perubahan keadaan atmosfer ini. Citra tersebut kemudian diolah dengan memanfaatkan layanan dari Google Colab. Didalam Google Colab, citra diubah kedalam bentuk array dan disini pula indeks komposit ikut ditambahkan. Data yang sudah didalam bentuk array inilah yang diujikan pada model dengan menggunakan k-fold cross validation untuk mencari model dengan performa terbaik.



Gambar 5. Alur kerja (*workflow*) penelitian

BAB IV


HASIL DAN PEMBAHASAN

4.1 Identifikasi Fitur Terbaik Penciri Area Tanam Padi


Berdasarkan heatmap (Gambar 6), dan tabel masing-masing band terhadap tiap-tiap kelas (Tabel V), informasi mengenai perbedaan nilai kelas dalam tiap band dapat diperoleh. Dari boxplot dan heatmap, dapat dilihat bahwa membedakan kelas-kelas yang ada hanya dengan menggunakan band bawaan dari Sentinel-2 saja tidak mungkin dilakukan karena hampir tidak ada perbedaan nilai antar kelas. Maka dari itu indeks komposit yang merupakan kombinasi dari beberapa band yang ada digunakan. Sementara saat menggunakan komposit indeks seperti NDVI atau NDWI, perbedaan antar kelas mulai terlihat walaupun belum bisa dipisahkan secara keseluruhan.

Dengan memperhatikan perbedaan nilai-nilai indeks komposit pada masing-masing kelas, akan terlihat bahwa indeks tertentu dapat membedakan satu atau dua kelas dari kelas lain, tetapi gagal dalam membedakan kelas lain tersebut. Sebagai contoh adalah NDWI yang mampu membedakan air dari kelas lain tapi tidak dapat membedakan antara area terbangun dengan bera, di mana satu-satunya indeks yang dapat membedakan kedua kelas tersebut adalah NDTI. Hal yang sama juga dapat diaplikasikan pada band dan kelas lain, sehingga masing-masing kelas memiliki fitur tertentu baik dalam satu indeks maupun lebih, yang dapat digunakan untuk membedakannya dengan kelas lain.

Sentinel 2



Landsat 8



Gambar 6. Heatmap masing-masing band dan indeks dari Sentinel 2 (atas) dan Landsat 8 (bawah) terhadap masing-masing kelas

Akan tetapi, bisa dilihat bahwa sawah dan hutan tidak mengikuti aturan tersebut di mana keduanya memiliki nilai yang cukup mirip pada setiap band dan indeks

komposit. Pada Sentinel 2 dan Landsat 8, walaupun NDVI terlihat mampu membedakan sawah dan hutan dari kelas lain di mana nilai ketiga indeks tersebut pada kelas sawah, nilai antara kedua kelas itu sendiri terlihat tidak berbeda jauh. Namun bila diperhatikan lebih lanjut, dapat dilihat bahwa keduanya memiliki pola di mana hutan memiliki nilai yang lebih tinggi daripada sawah di hampir tiap band dan indeks selain NDWI. Meski perbedaan nilai antara sawah dan hutan, baik pada NDVI terlihat tidak berbeda jauh, dengan menggabungkan informasi ini, mesin mungkin akan mampu membedakan antara kedua kelas tersebut. Dengan begitu, bila nilai indeks suatu pixel lebih tinggi di NDVI, tetapi lebih rendah di NDWI, kemungkinan besar pixel tersebut mewakili sawah. Selain itu terdapat dua fitur lain yang tampak benar-benar mampu membedakan kelas sawah dari kelas lain, termasuk hutan. Bila diperhatikan pada NDTI dan EVI pada kedua satelit, pada kelas sawah, nilai keduanya lebih tinggi bila dibandingkan dengan kelas terbangun, air, bera, tol, dan awan. Namun, nilai ini masih lebih rendah bila dibandingkan dengan nilai pada kelas hutan. Maka dari itu, penggunaan kedua fitur tersebut diharapkan dapat meningkatkan performa model dalam melakukan klasifikasi khususnya kelas sawah.

4.2 Identifikasi Model Terbaik Pengenalan Lahan Padi

Dalam penelitian ini, untuk menentukan model terbaik dibagi menjadi dua tahapan. Tahap pertama berfokus pada membandingkan model machine learning. Perbandingan ini dilakukan pada Sentinel 2 dan Landsat 8. Karena Sentinel 2 dan Landsat 8 memiliki resolusi spasial yang berbeda dimana Sentinel 2 memiliki

resolusi spasial sebesar 10m^2 untuk masing-masing pixel sementara Landsat 8 memiliki resolusi spasial sebesar 30m^2 untuk masing-masing pixel. Untuk memastikan bila terjadinya perbedaan performa model dari kedua satelit disebabkan oleh resolusi spasial atau alasan lain, citra Sentinel digunakan dua kali dimana pada penggunaan keduanya resolusi spasial dari citra diubah menjadi 30m^2 untuk masing-masing pixel. Berikutnya Sentinel 2 dengan resolusi spasial 10m^2 akan direfer dengan S2, Sentinel 2 dengan resolusi spasial 30m^2 akan direfer sebagai S2(30), dan Landsat 8 akan direfer sebagai L8.

Machine Learning

Semua model klasifikasi yang digunakan telah melalui proses grid search untuk melakukan hyperparameter tuning sehingga didapatkan parameter yang dapat memberikan hasil paling optimal untuk masing-masing model. Perbandingan performa dari semua metode klasifikasi untuk semua citra dapat dilihat dari Tabel 5. Nilai yang ditunjukkan merupakan hasil dari 10-fold cross validation, hal ini berarti bahwa seluruh sampel dibagi menjadi 10 bagian dengan ukuran yang sama, 9 bagian kemudian digunakan untuk training sementara satu bagian digunakan untuk testing. Proses training dan testing ini kemudian diulang 10 kali dimana pada tiap pengulangan bagian berbeda digunakan untuk testing. Hal ini dilakukan untuk meminimalkan bias yang terdapat pada model. Berdasat Tabel 5, hasil klasifikasi pada S2, selain pada model XGBoost menggunakan gbtree, selalu lebih baik bila dibandingkan dengan hasil pada data citra lain. Selain itu, model yang dijalankan

pada S2(30) juga menunjukkan performa yang lebih baik bila dibandingkan dengan performa model yang dijalankan pada Landsat 8.

Perbedaan performa yang cukup besar dari model yang dijalankan pada S2 dan S2(30) menunjukkan bahwa resolusi spasial memiliki pengaruh yang cukup besar terhadap performa model karena keduanya berasal dari satelit Sentinel 2 dan yang membedakan keduanya hanyalah resolusi spasial saja. Sementara perbedaan performa model yang dijalankan pada S2(30) dan L8 menunjukkan bahwa pada resolusi spasial yang sama sekalipun, terdapat faktor lain yang menyebabkan perbedaan performa model yang dijalankan di kedua citra tersebut. Bila dilihat dari tabel 4, tampak bahwa untuk band yang sama sekalipun, terdapat perbedaan panjang gelombang (wavelength) yang digunakan oleh masing-masing satelit. Hal inilah yang kemungkinan besar menjadi penyebab utama dari perbedaan performa model

Tabel 5. Hasil 10-fold cross validation dari semua model dengan menggunakan Sentinel 2 resolusi 10m, Sentinel 2 resolusi 30m, dan Landsat 8 pada kombinasi semua kelas.

Model Klasifikasi	F1-Score			Standard Deviasi		
	S2	S2(30)	L8	S2	S2(30)	L8
(1)	(2)	(3)	(4)	(5)	(6)	(7)
Random Forest	0,971	0,930	0,919	0,002	0,006	0,007
Decision Tree	0,952	0,906	0,888	0,003	0,006	0,010
Decision Tree with Bagging	0,971	0,932	0,922	0,002	0,005	0,008
Extra Trees	0,968	0,927	0,915	0,002	0,005	0,008
AdaBoost (Decision Tree)	0,942	0,919	0,911	0,003	0,005	0,008
Logistic Regression	0,803	0,814	0,834	0,037	0,010	0,017
Lineaer SVM	0,954	0,932	0,929	0,014	0,006	0,005
XGBoost (gbtree)	0,948	0,907	0,912	0,003	0,006	0,007
XGBoost (gblinear)	0,673	0,622	0,641	0,006	0,017	0,013

Untuk model machine learning terbaik sendiri tampak bahwa model random forest dan decision tree with bagging pada Sentinel 2 menunjukan performa yang sama. Maka dari itu, untuk menentukan model mana yang lebih baik beberapa hal lain ikut dipertimbangkan. Mulai dari tahap tuning dimana random forest memiliki keunggulan dengan banyaknya package yang membuat tuning model random forest lebih mudah dibandingkan dengan decision tree with bagging. Pada decision tree with bagging, proses tuning terdiri dari dua tahap, yang pertama adalah tuning dari model decision tree sendiri, dan yang kedua adalah tuning dari proses bagging yang dilakukan. Dari segi waktu, random forest pada S2 membutuhkan waktu 2,7 menit untuk memperoleh performa yang ditunjukkan, sementara decision tree with bagging pada S2 membutuhkan waktu 3,4 menit untuk memperoleh performa yang ditunjukkan pada Tabel 5. Dengan mempertimbangkan dua hal tersebut selain f1-

score, maka disimpulkan bahwa untuk model machine dengan performa terbaik adalah model random forest

Deep Learning

Performa dari kedua model *deep learning* yang digunakan, serta perbandingannya dengan model *random forest* dapat dilihat pada Tabel 6. Tabel tersebut menunjukkan hasil 10-fold *cross validation* masing-masing model pada seluruh kelas. Dalam penelitian ini, model *random forest* digunakan sebagai pembanding dari model *deep learning* yang digunakan terhadap model *machine learning*. Tabel VII menunjukkan nilai f1-score dari masing-masing kelas untuk setiap model yang digunakan. Jika diperhatikan, baik dari f1-score keseluruhan, maupun dari f1-score kelas sawah, CNN1D dan *random forest* menunjukkan performa yang lebih baik dibandingkan model MLP, namun tidak terdapat perbedaan yang signifikan antara model CNN1D dan *random forest*.

Tabel 6. Perbandingan performa model deep learning menggunakan 10-fold cross validation

Model	F1 Score		Precision		Recall	
	S2	L8	S2	L8	S2	L8
(1)	(2)	(3)	(4)	(5)	(6)	(7)
MLP	94,68%	91,13%	95,19%	92,95%	94,18%	89,19%
CNN 1D	97,03%	93,21%	97,16%	94,28%	96,89%	92,17%
Random Forest	96,64%	92,23%	96,64%	92,54%	96,64%	92,21%

Dapat dilihat pula dari kedua tabel tersebut bahwa model yang dijalankan pada Sentinel 2 menunjukkan performa yang lebih baik bila dibandingkan dengan model yang dijalankan pada Landsat 8. Hal yang bisa menyebabkan hal ini adalah resolusi

yang digunakan, di mana Sentinel 2 memiliki resolusi 10 meter, sementara Landsat 8 memiliki resolusi 30 meter. Satu hal yang perlu diperhatikan adalah bahwa nilai band yang diterima Sentinel 2 dan Landsat 8 berbeda walaupun keduanya menggunakan *wavelength* yang hampir sama, meskipun begitu, setelah data di normalisasi, nilai keduanya akan sangat mirip, selain pada SWIR 1 dan 2. Landsat 8 dan Sentinel 2 menggunakan *wavelength* yang berbeda untuk SWIR 1 dan 2 yang mengakibatkan perbedaan nilai pada indeks komposit yang memanfaatkan band tersebut, dalam kasus ini NDTI

Tabel 7. Perbandingan f1-score masing-masing kelas untuk tiap model

Kelas	MLP		CNN1D		Random Forest	
	S2	L8	S2	L8	S2	L8
(1)	(2)	(3)	(4)	(5)	(6)	(7)
Terbangun	93,05%	91,59%	94,72%	92,31%	94,18%	87,17%
Air	99,79%	93,99%	100,00%	96,17%	99,90%	99,38%
Sawah	90,98%	84,15%	95,43%	87,96%	95,16%	92,31%
Bera	93,95%	89,74%	96,54%	91,92%	96,74%	92,83%
Hutan	96,00%	96,15%	98,23%	97,00%	98,46%	96,45%
Jalan Tol	79,45%	80,29%	89,22%	86,76%	89,82%	84,13%
Awan	97,71%	97,72%	98,75%	98,06%	98,78%	97,38%

Nilai f1-score kelas sawah paling rendah berada di 84.15% pada model MLP Landsat 8 dan paling tinggi sebesar 95.43% pada model CNN1D Sentinel 2. Meski demikian, nilai tersebut tidak berbeda jauh dari hasil *random forest* pada Sentinel 2. Ini menunjukkan bahwa performa CNN1D tidak hanya lebih baik pada keseluruhan kelas, tapi juga khusus pada kelas sawah yang merupakan fokus dari penelitian ini seperti yang tampak pada Tabel 7. Selain itu, kesalahan klasifikasi yang terjadi dapat diperhatikan dari Gambar 7. Kesalahan klasifikasi kelas sawah

dapat berupa kelas sawah yang diklasifikasikan sebagai kelas lain, maupun sebaliknya. Kelas lain yang paling banyak diklasifikasikan sebagai sawah adalah kelas hutan, sementara kelas sawah paling banyak juga salah diklasifikasikan sebagai hutan.


True label	Terbangun	1598 18.00%	0 0.00%	26 0.29%	41 0.46%	1 0.01%	25 0.28%	6 0.07%
	Air	0 0.00%	477 5.37%	0 0.00%	1 0.01%	0 0.00%	0 0.00%	0 0.00%
	Sawah	6 0.07%	0 0.00%	1309 14.75%	12 0.14%	14 0.16%	0 0.00%	0 0.00%
	Bera	38 0.43%	0 0.00%	16 0.18%	1799 20.27%	0 0.00%	0 0.00%	1 0.01%
	Hutan	2 0.02%	0 0.00%	49 0.55%	1 0.01%	1717 19.34%	0 0.00%	0 0.00%
	Tol	12 0.14%	0 0.00%	0 0.00%	12 0.14%	0 0.00%	263 2.96%	6 0.07%
	Awan	14 0.16%	0 0.00%	2 0.02%	2 0.02%	0 0.00%	6 0.07%	1420 16.00%
		Terbangun	Air	Sawah	Bera	Hutan	Tol	Awan
		Predicted label						

Gambar 7. Confusion Matrix dari CNN1D pada Sentinel 2

4.3 Estimasi Luas Lahan Tanam Padi

Berdasarkan hasil estimasi menggunakan CNN1D, luas lahan tanam berdasarkan citra satelit Sentinel 2 seluas 66.230,51 hektar atau lebih luas 1.164,47 hektar (1,758%) bila dibandingkan dengan hasil estimasi KSA. Nilai ini diperoleh dengan membandingkan proporsi pixel yang diidentifikasi sebagai sawah terhadap luas kabupaten Nganjuk. Selain karena terdapat perbedaan resolusi spasial di mana KSA menggunakan sub segmen seluas 100 meter. Faktor yang mungkin

menjadi penyebab perbedaan hasil estimasi ini adalah terdapatnya awan pada citra satelit. Meskipun telah disediakan kelas tersendiri untuk awan agar dapat dilakukan estimasi berdasarkan proporsi lahan. Ditemukan bahwa bayangan dari awan dapat cukup berpengaruh dalam proses klasifikasi oleh model. Sebagaimana diperlihatkan pada Gambar 7, yang menunjukkan sebagian wilayah dengan awan dan bayang-bayang awan, model CNN1D dan *random forest* tampak kesulitan dalam memprediksikan daerah yang tertutup bayangan awan di mana *random forest* mengklasifikasikannya sebagai daerah terbangun sementara CNN1D mengklasifikasikannya sebagai genangan air.



Gambar 7. Visualisasi hasil segmentasi citra satelit sebagian wilayah Kabupaten Nganjuk.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Dalam penelitian ini, simulasi dan eksperimen mengenai pemanfaatan *deep learning* dalam melakukan pendeteksian area tanam padi pada citra satelit resolusi menengah. Dari simulasi yang dijalankan, dapat disarikan beberapa poin penting yakni: (1) fitur yang digunakan sudah dapat membedakan kelas dengan cukup baik, terutama *Normalized Difference Tillage Index* dan *Enhanced Vegetation Index* dalam membedakan kelas sawah; (2) model *Convolution Neural Network 1 Dimension* memberikan performa terbaik, baik pada seluruh kelas yang digunakan maupun khusus pada kelas sawah dengan nilai f1-score sebesar 97,03%, dan hasil klasifikasi pada citra satelit Sentinel 2 yang memiliki *spatial resolution* lebih tinggi menunjukkan performa yang lebih baik; (3) dengan mengasumsikan bahwa hasil Kerangka Sampel Area merupakan representasi dari *ground truth*, estimasi luas lahan tanam padi pada citra satelit resolusi menengah menggunakan *deep learning* menunjukkan akurasi yang cukup baik yaitu seluas 66.230,51 hektar.

5.2 Saran

Hal yang perlu dipertimbangkan adalah, karena pada penelitian ini menggunakan citra satelit Sentinel 2 dan Landsat 8, band yang digunakan hanyalah band yang terdapat pada kedua satelit. Sentinel 2 masih memiliki beberapa band yang tidak digunakan dalam penelitian ini. Band red-edge yang terdapat pada

Sentinel 2 menunjukkan korelasi antara indeks komposit dengan karakteristik vegetasi yang sangat dipengaruhi dengan band lain yang digunakan sebagai kombinasi (Astaoui, Dadaiss, Sebari, Benmansour, & Mohamed, 2021). Selain itu, penelitian ini berfokus pada mempelajari fitur spektral pada tingkatan pixel, direkomendasikan juga untuk mencoba model deep learning lain seperti Convolution Neural Network 2 Dimension yang dapat menggali fitur spasial seperti distribusi warna yang membuat model ini lebih robust pada data dengan fitur spasial. Untuk penelitian berikutnya dapat berfokus pada usia tanam dan produktivitas tanaman padi, sesuai kebutuhan publikasi Statistik Pertanian dan perlu dipertimbangkan juga penggunaan data multi temporal.

DAFTAR PUSTAKA

- Astaoui, G., Dadaiss, J. E., Sebari, I., Benmansour, S., & Mohamed, E. (2021). Mapping Wheat Dry Matter and Nitrogen Content Dynamics and Estimation of Wheat Yield Using UAV Multispectral Imagery Machine Learning and a Variety-Based Approach: Case Study of Morocco. *AgriEngineering*, 3(1), 29–49. <https://doi.org/10.3390/agriengineering3010003>
- Berndtsson, M., Hansson, J., Olsson, B., & Lundell, B. (2008). Thesis projects: A guide for students in computer science and information systems: Second edition. In *Thesis Projects: A Guide for Students in Computer Science and Information Systems: Second Edition* (2nd ed.). Springer. <https://doi.org/10.1007/978-1-84800-009-4>
- Borra, S., & Di Ciaccio, A. (2010). Measuring the prediction error. A comparison of cross-validation, bootstrap and covariance penalty methods. *Computational Statistics and Data Analysis*, 54(12), 2976–2989. <https://doi.org/10.1016/j.csda.2010.03.004>
- BPS-Statistics Indonesia. (n.d.). *PDRB ADHB Menurut Lapangan Usaha Kabupaten Nganjuk (Juta Rupiah), 2010–2020*. Retrieved March 26, 2021, from <https://nganjukkab.bps.go.id/statictable/2021/02/15/268/pdrb-adhb-menurut-lapangan-usaha-2010-2020.html>
- BPS-Statistics Indonesia. (2015). *Pedoman Pelaksanaan Uji Coba Sistem Kerangka Sampel Area*. [https://sirusa.bps.go.id/webadmin/pedoman/2016_3431_ped_Pedoman Pelaksanaan Uji Coba Kerangka Sampel Area \(KSA\)2015.pdf](https://sirusa.bps.go.id/webadmin/pedoman/2016_3431_ped_PedomanPelaksanaanUjiCobaKerangkaSampelArea(KSA)2015.pdf)

- BPS-Statistics Indonesia. (2019). Luas Panen dan Produksi Padi di Provinsi Jawa Timur 2019. *Badan Pusat Statistik, XVIII*(21/03), Diakses 2 Maret 2020.
- BPS-Statistics Indonesia. (2020). *Executive summary of paddy harvested area and production in Indonesia 2019*.
<https://www.bps.go.id/publication/2020/07/10/32247632fa792a2f3f28a644/ringkasan-eksekutif-luas-panen-dan-produksi-padi-di-indonesia-2019.html>
- Breiman, L. (2001). Random forests. *Machine Learning*, 45, 1–122.
<https://doi.org/10.1201/9780429469275-8>
- Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). *Classification And Regression Trees*.
- Drucker, H., Surges, C. J. C., Kaufman, L., Smola, A., & Vapnik, V. (1997). Support vector regression machines. *Advances in Neural Information Processing Systems, January*, 155–161.
- Fitriana, H. L., Suwarsono, S., Kusratmoko, E., & Supriatna, S. (2020). Mapping Burnt Areas Using the Semi-Automatic Object-Based Image Analysis Method. *International Journal of Remote Sensing and Earth Sciences (IJReSES)*, 17(1), 57. <https://doi.org/10.30536/j.ijreses.2020.v17.a3281>
- Fukushima, K. (1988). Neocognitron: A hierarchical neural network capable of visual pattern recognition. *Neural Networks*, 1(2), 119–130.
[https://doi.org/10.1016/0893-6080\(88\)90014-7](https://doi.org/10.1016/0893-6080(88)90014-7)
- Geurts, P., Ernst, D., & Wehenkel, L. (2006). Extremely randomized trees. *Machine Learning*, 63(1), 3–42. <https://doi.org/10.1007/s10994-006-6226-1>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
<http://www.deeplearningbook.org>

- Hastie, T., Tibshirani, R., & Friedman, J. (2013). The Elements of Statistical Learning Data Mining, Inference, and Prediction. *Encyclopedia of Systems Biology*, 508–508. https://doi.org/10.1007/978-1-4419-9863-7_941
- Helber, P., Bischke, B., Dengel, A., & Borth, D. (2019). Eurosat: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12(7), 2217–2226. <https://doi.org/10.1109/JSTARS.2019.2918242>
- Hu, W., Huang, Y., Wei, L., Zhang, F., & Li, H. (2015). Deep convolutional neural networks for hyperspectral image classification. *Journal of Sensors*, 2015. <https://doi.org/10.1155/2015/258619>
- Ienco, Di., Gaetano, R., Dupaquier, C., & Maurel, P. (2017). Land Cover Classification via Multitemporal Spatial Data by Deep Recurrent Neural Networks. *IEEE Geoscience and Remote Sensing Letters*, 14(10), 1685–1689. <https://doi.org/10.1109/LGRS.2017.2728698>
- Jean, N., Burke, M., Xie, M., Davis, W. M., Lobell, D. B., & Ermon, S. (2016). Combining satellite imagery and machine learning to predict poverty. *Science*, 353(6301), 790–794. <https://doi.org/10.1126/science.aaf7894>
- Jiang, W., He, G., Long, T., Ni, Y., Liu, H., Peng, Y., Lv, K., & Wang, G. (2018). Multilayer perceptron neural network for surface water extraction in landsat 8 OLI satellite images. *Remote Sensing*, 10(5), 1–22. <https://doi.org/10.3390/rs10050755>
- Kussul, N., Lemoine, G., Gallego, F. J., Skakun, S. V., Lavreniuk, M., & Shelestov, A. Y. (2016). Parcel-Based Crop Classification in Ukraine Using Landsat-8 Data and Sentinel-1A Data. *IEEE Journal of Selected Topics in Applied Earth*

- Observations and Remote Sensing*, 9(6), 2500–2508.
<https://doi.org/10.1109/JSTARS.2016.2560141>
- Parsa, I. M., Dirgahayu, D., Harini, S., & S, K. T. (2020). *Analisis Citra Multiresolusi Untuk Identifikasi Konversi Lahan Sawah Akibat Pembangunan Jalan Bebas Hambatan Di Kabupaten Subang , Jawa Barat (Multiresolution Image Analysis for Identification of Paddy Field Conversion Due To the Highway Development in S. 17(1), 21–32.*
- Parsa, M., Dirgahayu, D., Harini, S., Kushardono, D., Sensing, R., & Rebo, P. (2020). *OPTIMIZATION OF A RICE FIELD CLASSIFICATION MODEL BASED ON THE THRESHOLD INDEX OF MULTI-TEMPORAL LANDSAT. 17(1), 75–84.*
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. douard. (2019). Generating the blood exposome database using a comprehensive text mining and database fusion approach. *Environmental Health Perspectives*, 127(9), 2825–2830. <https://doi.org/10.1289/EHP4713>
- Polančič, G. (2007). *Empirical Research Method Poster*. Maribor.
- Rokhmatuloh, Supriatna, Pin, T. G., Hernina, R., Ardianto, R., Shidiq, I. P. A., & Wibowo, A. (2019). Paddy field mapping using UAV multi-spectral imagery. *International Journal of GEOMATE*, 17(61), 242–247.
<https://doi.org/10.21660/2019.61.icee408>
- Samuel, A. L. (1959). Some Studies in Machine Learning. *IBM Journal of Research and Development*, 3(3), 210–229.

<https://ieeexplore.ieee.org/stamp/stamp.jsp?tp=&arnumber=5392560>

Triscowati, D. W., Sartono, B., Kurnia, A., Dirgahayu, D., & Wijayanto, A. W. (2020). Classification of Rice-Plant Growth Phase Using Supervised Random Forest Method Based on Landsat-8 Multitemporal Data. *International Journal of Remote Sensing and Earth Sciences (IJReSES)*, 16(2), 187. <https://doi.org/10.30536/j.ijreses.2019.v16.a3217>

Triscowati, D. W., Sartono, B., Kurnia, A., Domiri, D. D., & Wijayanto, A. W. (2019). *Multitemporal remote sensing data for classification of food crops plant phase using supervised random forest*. 1131102(November 2019), 10. <https://doi.org/10.1117/12.2547216>

Widiatmaka, Ambarwulan, W., Santoso, P. B. K., Sabiham, S., Machfud, & Hikmat, M. (2016). Remote Sensing and Land Suitability Analysis to Establish Local Specific Inputs for Paddy Fields in Subang, West Java. *Procedia Environmental Sciences*, 33, 94–107. <https://doi.org/10.1016/j.proenv.2016.03.061>

(...Sengaja Dikosongkan...)

LAMPIRAN

Lampiran 1. Model Random Forest

```
model_rf = RandomForestClassifier(  
    n_estimators=200,  
    min_samples_leaf=1,  
    min_samples_split=2,  
    class_weight='balanced',  
    max_samples=0.3,  
    n_jobs=-1,  
    verbose=1,  
    random_state=0)
```

Lampiran 2. Model Extra Trees

```
model_et = ExtraTreesClassifier(  
    bootstrap=True,  
    class_weight='balanced',  
    criterion='gini',  
    max_features='auto',  
    max_samples=0.3,  
    min_samples_leaf=1,  
    min_samples_split=5,  
    n_estimators=100, n_jobs=-1,  
)
```

Lampiran 3. Model Decision Tree

Tanpa Bagging

```
model_dt = DecisionTreeClassifier(  
    class_weight='balanced',  
    criterion='gini',  
    max_depth=10,  
    max_features=None,  
    min_samples_leaf=1,  
    min_samples_split=2,  
)
```

Menggunakan Bagging

```
model_bag = BaggingClassifier(  
    DecisionTreeClassifier(  
        class_weight='balanced',  
        criterion='entropy',  
        max_depth=None,  
        max_features=None,  
        min_samples_leaf=1,  
        min_samples_split=2  
    ),  
    bootstrap=True,  
    max_features=1.0,  
    max_samples=0.3,  
    n_estimators=100,  
    n_jobs=-1  
)
```

Lampiran 4. Model Logistic Regression

```
model_lr = LogisticRegression(  
    C=100000.0,  
    class_weight='balanced',  
    fit_intercept=True,  
    intercept_scaling=1,  
    max_iter=200,  
    multi_class='auto',  
    penalty='l1',  
    solver='liblinear',  
    tol=0.0001)
```

Lampiran 5. Model Linear Support Vector Machine

```
model_sv=LinearSVC(  
    C=0.1,  
    class_weight='balanced',  
    loss='hinge',  
    max_iter=1000,  
    penalty='l2')
```

Lampiran 6. Model AdaBoost

```
model_ab = AdaBoostClassifier(  
    DecisionTreeClassifier(  
        criterion='gini',  
        splitter='best',  
        min_samples_leaf=1,  
        min_samples_split=2,  
        max_features='auto',  
        class_weight='balanced',  
        max_depth=10  
    ),  
    n_estimators=100,  
    algorithm='SAMME.R',  
    learning_rate=1.0  
)
```

Lampiran 7. Model XGBoost

```
# gbtrees

model_tb=XGBClassifier(
    booster='gbtree',
    n_estimators=100,
    reg_lambda=1,
    gamma=0,
    max_depth=3
)

# gblinear

model_lb=XGBClassifier(
    booster='gblinear',
    reg_lambda=1,
    updater='coord_descent',
    feature_selector='shuffle'
)
```

Lampiran 8. Model Multi Layer Perceptron

```
def get_model_dense(input_data, metrics=METRICS):
    model = keras.Sequential([
        keras.layers.Flatten(input_shape=input_data.shape[1:]),
        keras.layers.Dense(14, activation='relu'),
        keras.layers.Dense(7, activation='softmax')
    ])

    model.compile(
        optimizer='adam',
        loss='categorical_crossentropy',
        metrics=metrics)

    return model
```


Lampiran 9. Model Convolutional Neural Network

```
def get_cnn(input_data, metrics=METRICS):
    model = keras.Sequential([
        keras.layers.InputLayer(input_data.shape[1:]),
        keras.layers.Conv1D(filters=32, kernel_size=1,
                             activation="relu", padding="valid"),
        keras.layers.MaxPooling1D(1),
        keras.layers.Conv1D(filters=32, kernel_size=1,
                             activation="relu", padding="valid"),
        keras.layers.MaxPooling1D(1),
        keras.layers.Conv1D(filters=64, kernel_size=1,
                             activation="relu", padding="valid"),
        keras.layers.MaxPooling1D(1),
        keras.layers.Conv1D(filters=64, kernel_size=1,
                             activation="relu", padding="valid"),
        keras.layers.MaxPooling1D(1),
        keras.layers.Flatten(),
        keras.layers.Dense(120, activation="relu"),
        keras.layers.Dense(160, activation="relu"),
        keras.layers.Dense(7, activation="softmax")
    ])

    model.compile(
        optimizer='adam',
        loss='categorical_crossentropy',
        metrics=metrics)

    return model
```

RIWAYAT HIDUP

Penulis dilahirkan di Nganjuk pada tanggal 23 April 1996 dari pasangan Agus Yuni Purwanto dan Sukarti dan merupakan anak kedua dari dua bersaudara.

Tahun 2008 penulis menyelesaikan pendidikan dasar pada SDN 2 Lengkong, kemudian tahun 2011 menyelesaikan pendidikan menengah pertama di SMPN 1 Kertosono. Pada tahun 2014, penulis lulus dari SMAN 2 Kediri dan pada tahun yang sama mendapat kesempatan mengikuti pendidikan di Politeknik Statistika STIS.

Akhirnya pada tahun keempat (tahun 2021) penulis berhasil menyelesaikan pendidikan Program D IV di Politeknik Statistika STIS.